ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH



BÁO CÁO BÀI TẬP LỚN

Môn học: Kho dữ liệu và hệ hỗ trợ quyết định– CO4031

XÂY DỰNG KHO DỮ LIỆU BÁN LẺ VÀ HỆ HỖ TRỢ QUYẾT ĐỊNH LẬP KẾ HOẠCH BÁN HÀNG

Giảng viên hướng dẫn: ThS. Đỗ Thanh Thái
Lớp L02
Nhóm 5

STT	Họ và tên	MSSV	Đóng giớp
1	Đoàn Nguyễn Ngọc Bảo	2410222	100%
2	Đỗ Mai Thy	2413445	100%
3	Võ Minh Nhựt	2412555	100%

Thành phố Hồ Chí Minh, tháng 10 năm 2026

LỜI MỞ ĐẦU

Trước hết, nhóm chúng em xin gửi lời cảm ơn chân thành đến thầy

Mục lục

1 Giới thiệu đề tài **1**

1.1 Bối cảnh bài toán 1

1.2 Mục tiêu và đóng góp 2

1.3 Yêu cầu nghiệp vụ và chỉ tiêu phân tích 3

2 Khảo sát và tiền xử lý dữ liệu **5**

2.0.1 Tổng quan dữ liệu 5

2.1 Khảo sát dữ liệu 7

2.1.1 Tính đầy đủ, trùng lặp và miền giá trị 7

2.1.2 Tính nhất quán của định danh và phân cấp 8

2.2 Các bước tiền xử lý và kết quả 8

2.2.1 Quy tắc chuẩn hóa 8

2.2.2 Kết quả đầu ra 9

2.3 Thiết kế kho dữ liệu 10

2.3.1 Mô hình dữ liệu (Star Schema) 10

3 Phương pháp đề xuất **19**

3.1 Quy trình đưa dữ liệu vào kho 19

3.2 Nạp các bảng chiều và bảng sự kiện 19

3.3 Kiểm tra và đối chiếu kết quả nạp 20

3.4 Kết nối với phần phân tích 21

4 Phân tích OLAP và mô hình dự đoán **22**

4.1 Cách tổ chức phân tích OLAP 22

4.2 Tổng quan 23

4.2.1 Nhóm hàng Furniture 23

4.2.2 Nhóm hàng Office Supplies 23

4.2.3 Nhóm hàng Technology 24

4.2.4 Kết quả chung của ba nhóm hàng 25

4.3 Sản phẩm và thị trường 25

4.3.1 Phân tích doanh thu 25

4.3.2 Phân tích lợi nhuận 26

4.4 Khách hàng và đơn hàng 28
4.4.1 Doanh thu và lợi nhuận theo phân khúc 28
4.4.2 Vận chuyển và chiết khấu 29
4.5 Mô hình dự báo doanh thu 30
4.5.1 Mục tiêu và chuẩn bị dữ liệu 30
4.5.2 Phương pháp Holt–Winters và mô hình đối chứng 30
4.5.3 Cách chia dữ liệu và đánh giá 31
4.5.4 Kết quả kiểm tra và dự báo tháng tiếp theo 32

5 Demo Dashboard **35**

Tài liệu tham khảo **36**

Danh sách hình vẽ

1 Mô hình kiến trúc Star Schema . . . 10
2 Doanh thu và lợi nhuận theo tháng của nhóm Furniture . . . 23
3 Doanh thu và lợi nhuận theo tháng của nhóm Office Supplies . . . 24
4 Doanh thu và lợi nhuận theo tháng của nhóm Technology . . . 24
5 Doanh thu và lợi nhuận theo tháng của toàn bộ ba nhóm hàng . . . 25
6 Doanh thu theo phân nhóm sản phẩm trong giai đoạn 2011–2014 . . . 26
7 Mười lăm quốc gia có doanh thu cao nhất . . . 26
8 Lợi nhuận theo phân nhóm sản phẩm trong giai đoạn 2011–2014 . . . 27
9 Mười lăm quốc gia có lợi nhuận cao nhất . . . 27
10 Doanh thu theo phân khúc khách hàng . . . 28
11 Lợi nhuận theo phân khúc khách hàng . . . 29
12 Tổng phí vận chuyển theo phương thức giao hàng . . . 29
13 Tổng lợi nhuận theo các mức chiết khấu . . . 30
14 Doanh thu thực tế, dự báo kiểm tra năm 2014 và dự báo tháng 01/2015 theo ngành hàng . . . 33

Danh sách bảng

1 Yêu cầu nghiệp vụ, KPI và đầu ra phân tích . . . 3
2 Từ điển 27 thuộc tính của dữ liệu nguồn . . . 5
3 Miền giá trị và trung vị của các biến số . . . 7
4 Tên các thuộc tính sau khi chuẩn hóa . . . 9
5 Xác thực các khóa của mô hình Star Schema . . . 11
6 Phân loại chỉ số và quy tắc tổng hợp . . . 12
7 Thiết kế bảng sự kiện `Fact_Sales` . . . 13
8 Sáu khóa ngoại của `Fact_Sales` . . . 14
9 Thiết kế bảng `Dim_Date` . . . 15
10 Các CHECK đối chiếu thuộc tính của `Dim_Date` . . . 16
11 Thiết kế bảng `Dim_Customer` . . . 16
12 Thiết kế bảng `Dim_Product` . . . 17
13 Thiết kế bảng `Dim_Geography` . . . 17

14 Thiết kế bảng `Dim_Order` 18
15 Số bản ghi sau khi nạp kho dữ liệu 20
16 WAPE trên năm 2013 dùng để lựa chọn mô hình 32
17 Kết quả dự báo cuốn chiếu trên năm 2014 32
18 Dự báo doanh thu tháng 01/2015 theo đơn vị gốc 34

1 Giới thiệu đề tài

1.1 Bối cảnh bài toán

Trong hoạt động bán lẻ, việc lập kế hoạch bán hàng đòi hỏi nhà quản lý theo dõi đồng thời doanh thu, lợi nhuận, nhu cầu mua hàng và hiệu quả của các chính sách kinh doanh. Khi hoạt động kinh doanh trải rộng trên nhiều thị trường, sản phẩm và nhóm khách hàng, các chỉ tiêu tổng hợp chỉ phản ánh một phần tình hình. Một nhóm sản phẩm có doanh thu cao vẫn có thể mang lại lợi nhuận thấp hoặc thua lỗ. Vì vậy, nhà quản lý cần phân tích kết quả kinh doanh theo nhiều góc nhìn và đối chiếu giữa các giai đoạn trước khi lựa chọn phương án điều chỉnh.

Dữ liệu giao dịch ở dạng bảng phẳng cung cấp thông tin chi tiết về từng dòng hàng, nhưng chưa được tổ chức trực tiếp theo nhu cầu phân tích. Nếu mỗi báo cáo sử dụng một cách tổng hợp riêng, việc so sánh kết quả và truy tìm nguyên nhân chênh lệch sẽ gặp khó khăn. Chẳng hạn, biên lợi nhuận của một thị trường phải được tính từ tổng lợi nhuận và tổng doanh thu của cùng phạm vi dữ liệu; việc lấy trung bình đơn giản các tỷ lệ của từng dòng hàng có thể dẫn đến kết quả khác. Bài toán đặt ra là xây dựng một nền tảng dữ liệu thống nhất, có định nghĩa chỉ tiêu rõ ràng và cho phép phân tích từ mức tổng quan đến chi tiết.

Đề tài sử dụng bộ dữ liệu *Global Superstore Dataset* từ trang Kaggle. Qua khảo sát tệp, mỗi dòng biểu diễn một dòng hàng trong đơn hàng, bao gồm các thông tin về sản phẩm, khách hàng, địa lý, thời gian, doanh thu, lợi nhuận, số lượng, chiết khấu và vận chuyển. Đây là dữ liệu lịch sử được sử dụng để xây dựng và đánh giá hệ thống trong phạm vi bài tập lớn.

Từ nguồn dữ liệu này, nhóm lựa chọn đề tài *Xây dựng kho dữ liệu bán lẻ và hệ hỗ trợ quyết định lập kế hoạch bán hàng*. Kho dữ liệu đóng vai trò nền tảng để chuẩn hóa, lưu trữ và tổng hợp dữ liệu theo các chiều phân tích. Trên nền tảng đó, các truy vấn phân tích trực tuyến (Online Analytical Processing – OLAP) và dashboard hỗ trợ trả lời những câu hỏi như: doanh thu và lợi nhuận biến động thế nào theo thời gian; thị trường, ngành hàng hoặc phân khúc khách hàng nào đóng góp nhiều lợi nhuận; những nhóm sản phẩm nào cần được xem xét lại về hiệu quả kinh doanh.

Để kết quả phân tích phục vụ một quyết định cụ thể, hệ thống bổ sung thành phần hỗ trợ quyết định (Decision Support System – DSS) theo hướng dự báo doanh thu tháng tiếp theo cho ba ngành hàng Furniture, Office Supplies và Technology. Chuỗi doanh thu được tổng hợp từ kho dữ liệu theo tháng đặt hàng, sau đó sử dụng mô hình Holt–Winters và so sánh với phương pháp lấy doanh thu cùng tháng năm trước làm đối chứng. Người sử dụng xem dự báo cùng các chỉ số sai số trên dashboard để tham khảo khi lập mục tiêu doanh thu và lựa chọn ngành hàng cần theo dõi. Dự báo sử dụng lịch sử đến tháng

12/2014 để minh họa kế hoạch tháng 01/2015; kết quả không được diễn giải thành số lượng nhập hàng vì nguồn chưa có thông tin tồn kho và giá vốn đầy đủ. Phân tích chiết khấu thuộc phần OLAP mô tả lịch sử và không được dùng để khẳng định tác động nhân quả lên doanh thu hoặc lợi nhuận.

1.2 Mục tiêu và đóng góp

Mục tiêu tổng quát của đề tài là xây dựng một hệ thống tích hợp từ dữ liệu giao dịch bán lẻ đến phân tích đa chiều và hỗ trợ lập kế hoạch bán hàng. Hệ thống cung cấp cho nhà quản lý một nguồn số liệu thống nhất, khả năng xác định các nhóm kinh doanh cần được xem xét và dự báo doanh thu tháng tiếp theo kèm đánh giá sai số.

Các mục tiêu cụ thể bao gồm:

- **Xác định yêu cầu nghiệp vụ và chỉ tiêu phân tích:** làm rõ người sử dụng, câu hỏi kinh doanh, phạm vi dữ liệu và cách tính các chỉ tiêu như doanh thu, lợi nhuận, biên lợi nhuận, sản lượng và tăng trưởng theo thời gian.
- **Thiết kế kho dữ liệu đa chiều:** xây dựng mô hình hình sao (star schema), xác định mức chi tiết của bảng sự kiện là một dòng hàng và tổ chức các chiều thời gian, sản phẩm, khách hàng, địa lý và đơn hàng. Phương thức vận chuyển và mức ưu tiên được lưu tại chiều đơn hàng. Các khóa và quan hệ được thiết kế để bảo đảm khả năng liên kết và tránh tổng hợp trùng dữ liệu.
- **Hiện thực quy trình ETL:** xây dựng các bước trích xuất, biến đổi và nạp dữ liệu (Extract–Transform–Load), bao gồm lưu dữ liệu trung gian, chuẩn hóa kiểu dữ liệu, kiểm tra tính hợp lệ, xử lý định danh và ghi nhận ngoại lệ. Kết quả nạp được đối soát với nguồn và kiểm tra khi chạy lại quy trình.
- **Phát triển chức năng OLAP và giao diện phân tích:** xây dựng truy vấn tổng hợp trên kho dữ liệu và dashboard tương tác, hỗ trợ lọc theo nhiều chiều, tổng hợp theo cấp cao hơn (roll-up) và đi sâu vào chi tiết (drill-down).
- **Xây dựng thành phần DSS:** dự báo doanh thu tháng tiếp theo theo ngành hàng bằng Holt–Winters, lựa chọn mô hình trên năm 2013 và kiểm tra cuốn chiếu trên năm 2014. Kết quả được so sánh với dự báo cùng tháng năm trước bằng MAE, RMSE và WAPE trước khi huấn luyện lại để dự báo tháng 01/2015.
- **Kiểm thử và đánh giá hệ thống:** kiểm tra tính nhất quán của dữ liệu, độ đúng của các chỉ tiêu, sai số dự báo và khả năng vận hành xuyên suốt. Đồng thời, phân tích các hạn chế về chất lượng dữ liệu, thời gian quan sát và phạm vi áp dụng của mô hình hỗ trợ quyết định.

Trong phạm vi bài tập lớn, các đóng góp dự kiến của đề tài tập trung vào ba nội dung:

- **Một nền tảng dữ liệu có thể kiểm tra và tái lập:** kết hợp mô hình kho dữ liệu, từ điển dữ liệu và quy trình ETL có kiểm tra, giúp truy vết số liệu từ báo cáo về nguồn.
- **Một luồng phân tích gắn với bài toán quản lý:** kết nối các chỉ tiêu tổng quan với khả năng phân tích chi tiết để xác định những thị trường hoặc nhóm sản phẩm cần được rà soát.
- **Một chức năng dự báo có đánh giá:** trình bày doanh thu dự báo theo ngành hàng, kết quả so sánh với phương pháp đối chứng và giới hạn áp dụng, giúp người sử dụng có thêm căn cứ khi lập mục tiêu bán hàng tháng tiếp theo.

1.3 Yêu cầu nghiệp vụ và chỉ tiêu phân tích

Người sử dụng được giả định là nhà quản lý kinh doanh, quản lý sản phẩm và người phụ trách lập kế hoạch. Bài toán nghiệp vụ là tổ chức dữ liệu bán lẻ thành một nguồn đáng tin cậy để đánh giá hiệu quả kinh doanh và cung cấp đầu vào cho dự báo doanh thu. Bảng 1 liên kết từng câu hỏi với chỉ tiêu, chiều phân tích và đầu ra cần có.

Bảng 1: Yêu cầu nghiệp vụ, KPI và đầu ra phân tích

Mã	Câu hỏi nghiệp vụ	Kết quả yêu cầu	Chiều phân tích	Đầu ra
BR01	Doanh thu và lợi nhuận biến động ra sao theo tháng, quý, năm?	Tổng doanh thu, tổng lợi nhuận, biên lợi nhuận và tăng trưởng theo tháng hoặc cùng kỳ.	Dim_Date theo ngày đặt.	OLAP, dashboard và chuỗi dự báo.
BR02	Ngành hàng, phân nhóm và sản phẩm nào đóng góp nhiều hoặc hoạt động kém?	Tổng doanh thu, lợi nhuận, số lượng và biên lợi nhuận.	Dim_Product.	OLAP và dashboard.
BR03	Quốc gia, vùng và thị trường nào có kết quả tốt hoặc xấu?	Tổng doanh thu, lợi nhuận và biên lợi nhuận.	Dim_Geography.	OLAP và dashboard.
BR04	Khách hàng và phân khúc nào đóng góp doanh thu, lợi nhuận?	Tổng doanh thu, lợi nhuận và số mã khách hàng phân biệt.	Dim_Customer.	OLAP và dashboard.

Mã	Câu hỏi nghiệp vụ	Kết quả yêu cầu	Chiều phân tích	Đầu ra
BR05	Chiết khấu liên hệ như thế nào với lợi nhuận và tình trạng bán lỗ?	Tổng lợi nhuận, số dòng lỗ và tỷ lệ dòng lỗ theo nhóm mức chiết khấu.	Discount tại Fact; sản phẩm và địa lý.	OLAP mô tả và dashboard.
BR06	Phí vận chuyển khác nhau thế nào theo phương thức và mức ưu tiên?	Tổng phí vận chuyển, số đơn phân biệt và phí bình quân mỗi đơn.	Dim_Order.	OLAP và dashboard.
BR07	Số dòng hàng và số đơn hàng được đếm chính xác thế nào?	Số dòng Fact; số tổ hợp phân biệt mã đơn, ngày đặt và mã khách hàng.	Fact_Sales và Dim_Order.	Đối soát, OLAP và KPI dashboard.
BR08	Doanh thu tháng tiếp theo của từng ngành hàng được dự báo thế nào?	Chuỗi tổng doanh thu 48 tháng mỗi ngành; dự báo tháng tiếp theo và MAE, RMSE, WAPE.	Dim_Date và Dim_Product.	Mô hình Holt–Winters và trang dự báo DSS.

Các chỉ tiêu doanh thu, lợi nhuận, số lượng và phí vận chuyển được tính bằng tổng trên các dòng Fact thuộc phạm vi đã chọn. Số khách hàng là số `customer_id` phân biệt; số dòng hàng là số bản ghi Fact; số đơn là số tổ hợp phân biệt `(order_id, order_date, customer_id)`. Phí bình quân mỗi đơn bằng tổng phí vận chuyển chia số đơn trong cùng phạm vi. Tỷ lệ dòng lỗ bằng số dòng có `profit < 0` chia tổng số dòng. Không cộng trực tiếp Discount hoặc số đơn giữa những nhóm sản phẩm có thể cùng chứa một đơn.

Biên lợi nhuận tổng hợp bằng tổng lợi nhuận chia tổng doanh thu; tăng trưởng được so với tháng trước hoặc cùng tháng năm trước. Các tỷ lệ được để NULL khi mẫu số bằng 0 hoặc chưa có kỳ so sánh. Công thức và cách sử dụng các thao tác OLAP được trình bày tại Mục 4; phương pháp dự báo DSS được trình bày tại Mục 4.5.

2 Khảo sát và tiền xử lý dữ liệu

2.0.1 Tổng quan dữ liệu

Đề tài sử dụng bộ dữ liệu *Global Superstore Dataset* trên Kaggle [1]. Tệp được khảo sát là `superstore.csv`, gồm 51.290 dòng và 27 thuộc tính. Ngày đặt hàng nằm trong khoảng 01/01/2011–31/12/2014; ngày gửi hàng nằm trong khoảng 03/01/2011–07/01/2015. Phạm vi địa lý gồm 147 quốc gia và 3.636 tên thành phố phân biệt. Số tên thành phố không đồng nghĩa với số thực thể địa lý duy nhất, vì các địa điểm khác nhau có thể trùng tên. Dữ liệu gồm 7 thị trường, 13 vùng, 3 ngành hàng, 17 nhóm sản phẩm và 3 phân khúc khách hàng.

Mức chi tiết của dữ liệu là một dòng hàng trong đơn hàng. Nhiều dòng có thể thuộc cùng một đơn; vì vậy, số dòng không phải số đơn hàng. Các thuộc tính kết hợp thông tin về giao dịch, sản phẩm, khách hàng, địa lý và vận chuyển, phù hợp để tổ chức kho dữ liệu đa chiều phục vụ phân tích bán lẻ.

Phạm vi sử dụng là phân tích dữ liệu lịch sử và chuẩn bị đầu vào cho kho dữ liệu, OLAP và DSS. Nguồn hiện tại không có các trường riêng về tồn kho, giá vốn, giá niêm yết hoặc ngày giao hàng thực tế. Đơn vị tiền tệ và quan hệ giữa lợi nhuận với phí vận chuyển cũng chưa được xác minh từ định nghĩa nguồn. Do đó, các đại lượng tiền tệ được trình bày theo đơn vị ghi trong dữ liệu, không tự quy đổi hoặc diễn giải thành số liệu hiện tại của doanh nghiệp.

Các thuộc tính của bộ dữ liệu gốc được mô tả trong Bảng 2,. Kiểu dữ liệu trong bảng là kiểu sử dụng sau khi chuẩn hóa: định danh và biến phân loại được giữ dưới dạng chuỗi; ngày được chuyển thành kiểu ngày; số lượng và mã dòng là số nguyên; các đại lượng tiền tệ và tỷ lệ sử dụng kiểu số thực.

Bảng 2: Từ điển 27 thuộc tính của dữ liệu nguồn

STT	Thuộc tính	Kiểu	Ý nghĩa và lưu ý sử dụng
1	`Category`	Chuỗi	Ngành hàng: *Furniture* (nội thất), *Office Supplies* (văn phòng phẩm), *Technology* (công nghệ).
2	`City`	Chuỗi	Thành phố theo nguồn; tên thành phố không được dùng làm khóa địa lý độc lập.
3	`Country`	Chuỗi	Quốc gia gắn với dòng hàng, gồm 147 giá trị. Không tự giả định mỗi quốc gia chỉ thuộc một vùng hoặc một thị trường trong phân loại nguồn.
4	`Customer.ID`	Chuỗi	Mã khách hàng nguồn; có 4.873 giá trị phân biệt. Giữ nguyên để liên kết và kiểm tra định danh.

STT	Thuộc tính	Kiểu	Ý nghĩa và lưu ý sử dụng
5	`Customer.Name`	Chuỗi	Tên khách hàng; có 795 tên phân biệt. Không gộp các mã khách hàng chỉ dựa trên tên trùng nhau.
6	`Discount`	Số thực	Tỷ lệ chiết khấu dạng 0–1; giá trị 0,2 tương ứng 20%. Không cộng trực tiếp các tỷ lệ giữa các dòng hàng.
7	`Market`	Chuỗi	Thị trường kinh doanh, gồm *US*, *Canada*, *EU*, *LATAM*, *APAC*, *Africa*, *EMEA*.
8	记录数 (Cột đếm bản ghi)	Số nguyên	Có giá trị bằng 1 ở tất cả các dòng. Không mang thêm thông tin nghiệp vụ; bỏ khỏi bảng chuẩn hóa và sử dụng phép đếm dòng khi cần.
9	`Order.Date`	Ngày	Ngày đặt hàng, ban đầu được lưu dưới dạng chuỗi có phần giờ bằng 0; chuyển sang kiểu ngày để phân tích thời gian.
10	`Order.ID`	Chuỗi	Mã đơn hàng nguồn. Không dùng riêng làm khóa đơn vì một mã có thể gắn với nhiều ngày đặt hoặc khách hàng.
11	`Order.Priority`	Chuỗi	Mức ưu tiên xử lý: *Critical*, *High*, *Medium*, *Low*. Đây là biến phân loại, không phải đại lượng để cộng hoặc lấy trung bình.
12	`Product.ID`	Chuỗi	Mã sản phẩm nguồn; có 10.292 mã phân biệt. Một số mã gắn với nhiều tên sản phẩm nên cần quy tắc định danh bổ sung.
13	`Product.Name`	Chuỗi	Tên sản phẩm theo nguồn, dùng để mô tả và phân biệt các biến thể cùng mã.
14	`Profit`	Số thực	Lợi nhuận của dòng hàng theo nguồn. Giá trị âm phản ánh dòng hàng lỗ và được giữ lại phục vụ phân tích.
15	`Quantity`	Số nguyên	Số lượng sản phẩm bán trên dòng hàng, nằm trong khoảng 1–14.
16	`Region`	Chuỗi	Vùng kinh doanh theo cách phân loại của nguồn, gồm 13 giá trị như *West*, *Central*, *Southeast Asia*.
17	`Row.ID`	Số nguyên	Định danh dòng bán hàng nguồn. Toàn bộ 51.290 giá trị là duy nhất; giữ nguyên giá trị dưới tên `row_id`, không cấp lại số thứ tự cho dòng.
18	`Sales`	Số thực	Doanh thu của dòng hàng theo nguồn. Tệp hiện tại chỉ chứa các giá trị nguyên; chuyển sang số thực để thống nhất xử lý, không suy ra hoặc khôi phục phần thập phân.
19	`Segment`	Chuỗi	Phân khúc khách hàng: *Consumer*, *Corporate*, *Home Office*.

STT	Thuộc tính	Kiểu	Ý nghĩa và lưu ý sử dụng
20	`Ship.Date`	Ngày	Ngày gửi hoặc xuất hàng theo nguồn; không phải ngày giao đến khách hàng.
21	`Ship.Mode`	Chuỗi	Phương thức vận chuyển: *Same Day*, *First Class*, *Second Class*, *Standard Class*.
22	`Shipping.Cost`	Số thực	Phí vận chuyển ghi trên dòng hàng. Không tự trừ thêm khỏi `Profit` khi chưa xác minh cách tính lợi nhuận nguồn.
23	`State`	Chuỗi	Bang hoặc tỉnh theo nguồn; cần kết hợp với quốc gia khi xác định địa điểm.
24	`Sub.Category`	Chuỗi	Nhóm sản phẩm chi tiết thuộc ngành hàng; có 17 giá trị như *Chairs*, *Paper*, *Phones*.
25	`Year`	Số nguyên	Năm nguồn, khớp hoàn toàn với năm của ngày đặt. Sau đối chiếu, thuộc tính năm phục vụ phân tích được lưu tại `dim_date`, không lặp trong bảng dòng bán hàng.
26	`Market2`	Chuỗi	Nhóm thị trường cấp tổng hợp, gồm 6 giá trị. *US* và *Canada* được gộp thành *North America*; các thị trường còn lại giữ nguyên.
27	`weeknum`	Số nguyên	Số tuần nguồn, từ 1–53

2.1 Khảo sát dữ liệu

2.1.1 Tính đầy đủ, trùng lặp và miền giá trị

Kiểm tra toàn bộ 27 thuộc tính không phát hiện ô thiếu hoặc chuỗi rỗng sau khi bỏ khoảng trắng hai đầu. Không có dòng trùng hoàn toàn và không có mã `Row.ID` bị lặp. Các giá trị ngày đều chuyển đổi được theo định dạng nguồn; không có trường hợp ngày gửi trước ngày đặt. Số lượng bán luôn là số nguyên dương; chiết khấu nằm trong khoảng 0–0,85; doanh thu và phí vận chuyển không âm.

Bảng 3: Miền giá trị và trung vị của các biến số

Biến	Nhỏ nhất	Trung vị	Lớn nhất
Doanh thu	0	85	22.638
Lợi nhuận	−6.599,978	9,24	8.399,976
Số lượng	1	3	14
Chiết khấu	0%	0%	85%
Phí vận chuyển	0,002	7,79	933,57

Có 12.544 dòng lợi nhuận âm và 1 dòng doanh thu bằng 0. Đây là những trường hợp

cần lưu ý khi phân tích, nhưng không bị loại chỉ vì khác biệt so với phần lớn dữ liệu. Dòng doanh thu bằng 0 có mã nguồn `Row.ID = 35398`; biên lợi nhuận của dòng này không xác định. Các giá trị doanh thu, lợi nhuận hoặc phí vận chuyển lớn cũng được giữ nguyên, vì chưa có căn cứ nghiệp vụ để xem chúng là lỗi hoặc loại theo một ngưỡng thống kê.

2.1.2 Tính nhất quán của định danh và phân cấp

Mặc dù không có dòng trùng hoàn toàn, các mã nghiệp vụ chưa bảo đảm quan hệ một-một với thuộc tính mô tả:

- **Sản phẩm:** 457 mã `Product.ID` gắn với nhiều tên, ảnh hưởng đến 4.392 dòng. Trong đó, 1 mã gắn với 2 nhóm sản phẩm khác nhau, ảnh hưởng đến 12 dòng. Không có căn cứ để tự chọn một tên hoặc một nhóm làm giá trị đúng.
- **Đơn hàng:** 659 mã `Order.ID` gắn với nhiều ngày đặt và 659 mã gắn với nhiều khách hàng. Khi xét đồng thời tổ hợp mã đơn, ngày đặt và mã khách hàng, có **660 mã đơn nguồn** chứa nhiều tổ hợp khác nhau. Hai số 659 không được cộng lại vì các tập trường hợp có phần giao nhau.
- **Khách hàng:** mỗi mã khách hàng chỉ gắn với một tên và một phân khúc trong tệp hiện tại. Tuy nhiên, nhiều mã có cùng tên; không thể kết luận chúng là cùng một khách hàng.
- **Địa lý:** 3 quốc gia gắn với nhiều giá trị `Region` và 2 quốc gia gắn với nhiều giá trị `Market`. Vì vậy, không tự áp đặt quan hệ phân cấp quốc gia–vùng–thị trường thành một cây duy nhất khi thiết kế kho.

2.2 Các bước tiền xử lý và kết quả

2.2.1 Quy tắc chuẩn hóa

Quy trình xử lý được thực hiện theo các bước sau:

1. **Bảo toàn đầu vào và khảo sát cấu trúc:** giữ nguyên CSV nguồn, kiểm tra danh sách cột và lưu dấu kiểm tra tệp. Khảo sát giá trị gốc trước khi chuyển kiểu;
2. **Chuẩn hóa tên và văn bản:** thống nhất tên cột theo dạng chữ thường và dấu gạch dưới, chẳng hạn `Order.Date` thành `order_date`. Văn bản được chuẩn hóa Unicode NFC và bỏ khoảng trắng hai đầu. Trong tệp hiện tại, bước kiểm tra này không làm thay đổi ô văn bản nào.
3. **Chuyển kiểu và kiểm tra tính hợp lệ:** chuyển hai cột ngày theo định dạng nguồn, mã dòng và số lượng sang số nguyên, các đại lượng tiền tệ và tỷ lệ sang số thực. Kiểm

tra miền giá trị, tính duy nhất của mã dòng và thứ tự ngày đặt–ngày gửi. Dòng không hợp lệ được tách riêng kèm lý do; lần xử lý hiện tại không có dòng phải cách ly.

4. **Tổ chức thêm bớt thuộc tính:** Do cột 记录数 (Cột đếm bản ghi) không mang thêm thông tin nghiệp vụ cũng như không có ý nghĩa đóng góp nên được loại bỏ. Đồng Thời cột `Year` có thể truy xuất từ ngày đặt nên cũng được loại bỏ. Thêm một thuộc tính mới là biên lợi nhuận `profit_margin`, biên lợi nhuận dòng được xác định bởi

$$m_i = \begin{cases} p_i / s_i, & s_i \neq 0, \\ \text{không xác định}, & s_i = 0, \end{cases}$$

trong đó p_i và s_i là lợi nhuận và doanh thu của dòng i. Khi tổng hợp cho phạm vi G, sử dụng $\sum_{i \in G} p_i / \sum_{i \in G} s_i$ nếu tổng doanh thu khác 0; không lấy trung bình đơn giản các tỷ lệ dòng. Giá trị không xác định được phân biệt với tỷ lệ bằng 0.

2.2.2 Kết quả đầu ra

Bảng 4: Tên các thuộc tính sau khi chuẩn hóa

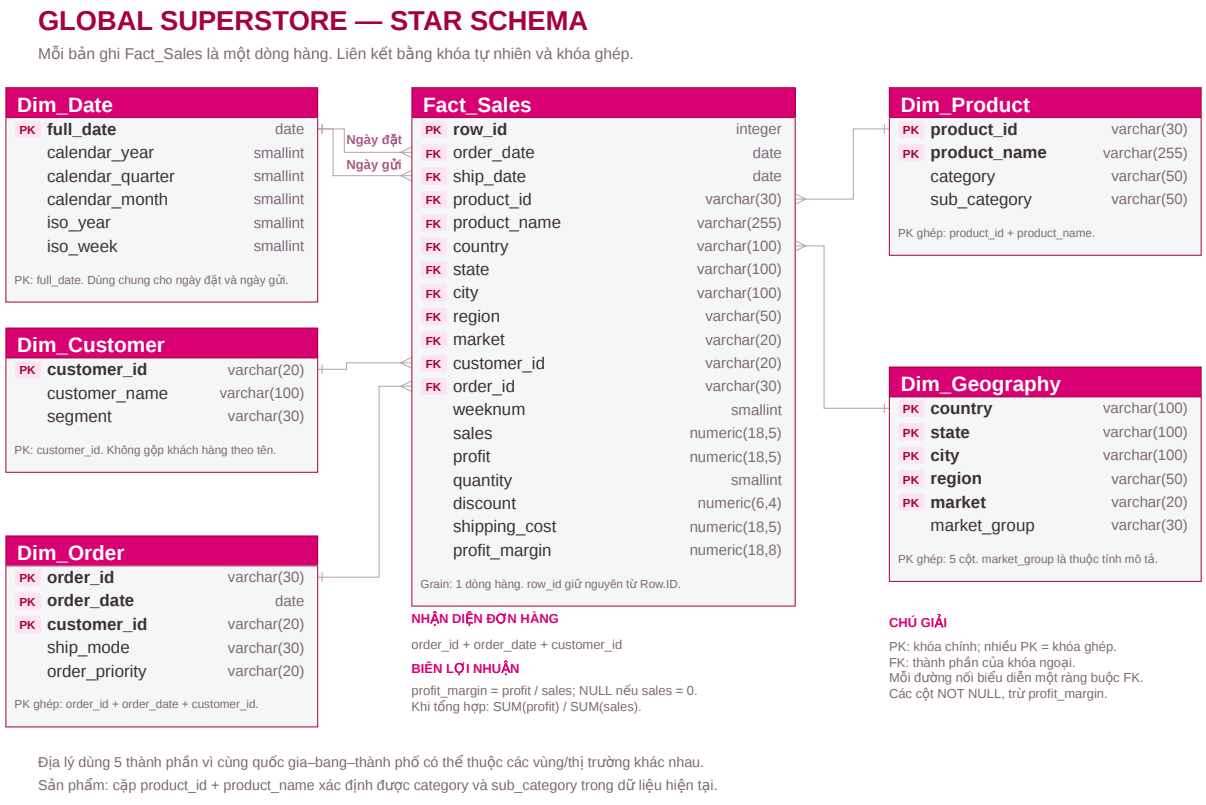
Tên thuộc tính ban đầu	Tên sau chuẩn hóa
Category	category
City	city
Country	country
Customer.ID	customer_id
Customer.Name	customer_name
Discount	discount
Market	market
Order.Date	order_date
Order.ID	order_id
Order.Priority	order_priority
Product.ID	product_id
Product.Name	product_name
Profit	profit
Quantity	quantity
Region	region
Row.ID	row_id
Sales	sales
Segment	segment
Ship.Date	ship_date

Tên thuộc tính ban đầu	Tên sau chuẩn hóa
`Ship.Mode`	`ship_mode`
`Shipping.Cost`	`shipping_cost`
`State`	`state`
`Sub.Category`	`sub_category`
`Market2`	`market_group`
`weeknum`	`weeknum`
Thuộc tính phát sinh từ `Profit/Sales`	`profit_margin`

Dữ liệu sau xử lý được lưu thành tệp CSV mới là `superstore_processed.csv`, gồm 51.290 dòng và 26 cột. Số thuộc tính được xác định bằng 27 cột nguồn trừ cột đếm bản ghi và `Year`, sau đó thêm `profit_margin`. Cột `weeknum` được giữ nguyên; thuộc tính phát sinh `profit_margin` nhận NULL khi `Sales = 0`.

2.3 Thiết kế kho dữ liệu

2.3.1 Mô hình dữ liệu (Star Schema)



Hình 1: Mô hình kiến trúc Star Schema

Nhóm lựa chọn lược đồ hình sao (Star Schema) vì các câu hỏi phân tích của đề tài đều xoay quanh kết quả bán hàng theo thời gian, sản phẩm, khách hàng, địa lý và đơn hàng. Với cách tổ chức này, các đại lượng như doanh thu, lợi nhuận, số lượng và phí vận chuyển được đặt tại bảng sự kiện; các thông tin mô tả được tập hợp trong từng bảng chiều. Cấu trúc tập trung giúp việc xây dựng truy vấn tổng hợp và bộ lọc trên dashboard dễ theo dõi. Các cấp phân tích như năm–quý–tháng hay ngành hàng–nhóm sản phẩm được giữ trong cùng bảng chiều, nên không cần tách thêm nhiều bảng và nối qua nhiều cấp như lược đồ bông tuyết.

Lược đồ gồm bảng sự kiện `Fact_Sales` và năm bảng chiều: `Dim_Date`, `Dim_Customer`, `Dim_Product`, `Dim_Geography` và `Dim_Order`. Mức chi tiết của `Fact_Sales` là một dòng hàng, được nhận diện bằng `row_id` giữ nguyên từ `Row.ID`. Mỗi bản ghi sự kiện liên kết đến một bản ghi tương ứng trong từng chiều; một bản ghi chiều có thể được sử dụng bởi nhiều dòng bán hàng. Riêng `Dim_Date` được dùng với hai vai trò là ngày đặt và ngày gửi hàng.

Thiết kế sử dụng các thuộc tính có sẵn để xác định khóa. Với những mã nguồn chưa duy nhất, nhóm sử dụng khóa ghép thay vì gộp các bản ghi theo một mã đơn lẻ. Các thành phần của khóa ghép phải được sử dụng đồng thời khi liên kết bảng sự kiện với bảng chiều. Cột `weeknum` nguồn được giữ tại `Fact_Sales`, còn năm, quý, tháng và lịch tuần ISO được quản lý trong `Dim_Date`. Biên lợi nhuận khi tổng hợp được tính từ tổng lợi nhuận chia tổng doanh thu, không cộng hoặc lấy trung bình đơn giản các tỷ lệ dòng.

Xác thực các khóa đã chọn

Các khóa được kiểm tra trực tiếp trên toàn bộ 51.290 dòng của tệp `data/superstore.csv` trong bản triển khai chính. Với mỗi khóa, nhóm đếm số tổ hợp phân biệt và kiểm tra số giá trị của từng thuộc tính mô tả trong cùng một nhóm khóa. Một nhóm được xem là mâu thuẫn khi cùng khóa nhưng có nhiều giá trị cho ít nhất một thuộc tính mô tả. Kết quả trong Bảng 5 cho thấy các khóa đã chọn xác định nhất quán các thuộc tính được kiểm tra trong dữ liệu hiện tại.

Bảng 5: Xác thực các khóa của mô hình Star Schema

Bảng	Khóa được chọn	Số tổ hợp	Số nhóm mâu thuẫn
Dim_Customer	`customer_id`	4.873	0
Dim_Product	`product_id`, `product_name`	10.768	0
Dim_Geography	`country`, `state`, `city`, `region`, `market`	3.819	0
Dim_Order	`order_id`, `order_date`, `customer_id`	25.754	0

Bảng	Khóa được chọn	Số tổ hợp	Số nhóm mâu thuẫn
Fact_Sales	`row_id`	51.290	0; mỗi mã dòng xuất hiện đúng một lần
Dim_Date	`full_date`, lịch liên tục 01/01/2011–07/01/2015	1.468	Không áp dụng; lịch được phát sinh

Các thuộc tính mô tả được kiểm tra gồm tên và phân khúc khách hàng; ngành hàng và phân nhóm sản phẩm; nhóm thị trường của tổ hợp địa lý; phương thức gửi, mức ưu tiên, ngày gửi và địa điểm của tổ hợp đơn hàng. Riêng `row_id` được kiểm tra tính duy nhất và sự nhất quán của toàn bộ thuộc tính nguồn còn lại. Lịch `Dim_Date` được phát sinh liên tục, bao phủ cả ngày đặt và ngày gửi, nên 1.468 là số ngày lịch chứ không phải số ngày có giao dịch. Kết quả xác thực khóa mô tả tính nhất quán của bộ dữ liệu hiện tại, không thay thế các ràng buộc PK, FK và kiểm tra dữ liệu khi nạp kho.

Phân loại cách tổng hợp chỉ số

Bảng 6 thống nhất cách sử dụng các chỉ số trong OLAP và dashboard. Các tổng chỉ được cộng giữa những tập dòng không chồng lặp; phép nối Dimension phải giữ nguyên số dòng Fact để tránh làm tăng số liệu.

Bảng 6: Phân loại chỉ số và quy tắc tổng hợp

Chỉ số	Phân loại	Cách tổng hợp và lưu ý
`sales`	Cộng được	`SUM(sales)` trong phạm vi phân tích.
`profit`	Cộng được	`SUM(profit)`; giữ cả lợi nhuận âm.
`quantity`	Cộng được	`SUM(quantity)`; phản ánh tổng số lượng sản phẩm bán.
`shipping_cost`	Cộng được	`SUM(shipping_cost)` theo giá trị từng dòng nguồn; không tự trừ thêm khỏi Profit.
`discount`	Không cộng trực tiếp	Phân tích theo nhóm mức chiết khấu. Nếu tính trung bình phải nêu rõ cách tính và trọng số, nếu có.
`profit_margin`	Không cộng trực tiếp	Tính lại bằng tổng lợi nhuận chia tổng doanh thu trong cùng phạm vi; NULL nếu tổng doanh thu bằng 0. Không dùng tổng hoặc trung bình đơn giản các tỷ lệ dòng.

Chỉ số	Phân loại	Cách tổng hợp và lưu ý
Số dòng hàng	Đếm dòng	`COUNT(*)` trên Fact sau khi áp dụng bộ lọc.
Số đơn hàng	Đếm tổ hợp phân biệt	Đếm đồng thời `order_id`, `order_date`, `customer_id` trong phạm vi đang lọc. Một đơn có thể chứa nhiều sản phẩm nên không cộng số đơn giữa các nhóm có thể giao nhau.

Các bảng dưới đây mô tả tên trường, kiểu dữ liệu và ràng buộc trên PostgreSQL, đối chiếu với tệp `01_create_tables.sql`. PK là khóa chính; FK là khóa ngoại; NN là `NOT NULL`, yêu cầu trường có giá trị; CHECK là điều kiện kiểm tra dữ liệu. Khi nhiều trường cùng được ghi là thành phần PK ghép, tính duy nhất áp dụng cho toàn bộ tổ hợp, không áp dụng riêng cho từng trường. **Chi tiết thiết kế các bảng (Star Schema)**

Bảng sự kiện `Fact_Sales`

`Fact_Sales` lưu một dòng cho mỗi `Row.ID` nguồn, với khóa chính `row_id` được giữ nguyên. Bảng có 19 trường và sáu khóa ngoại đến năm bảng chiều; hai khóa ngoại thời gian cùng tham chiếu `Dim_Date`. Các ký hiệu FK1–FK6 dưới đây được mô tả theo toàn bộ tổ hợp trong Bảng 8.

Bảng 7: Thiết kế bảng sự kiện `Fact_Sales`

Tên trường	Kiểu dữ liệu	Ràng buộc	Mô tả
`row_id`	`integer`	PK; CHECK > 0	Định danh dòng gốc, không cấp lại số thứ tự; PK bao hàm NN.
`order_date`	`date`	NN; FK1, FK6	Ngày đặt; đồng thời là thành phần khóa tham chiếu đơn hàng.
`ship_date`	`date`	NN; FK2	Ngày gửi; không trước ngày đặt.
`product_id`	`varchar(30)`	NN; FK4	Mã sản phẩm; tham gia FK ghép với tên.
`product_name`	`varchar(255)`	NN; FK4	Tên sản phẩm, bảo toàn các sản phẩm cùng mã nhưng khác tên.
`country`	`varchar(100)`	NN; FK5	Quốc gia, thành phần khóa địa lý.
`state`	`varchar(100)`	NN; FK5	Bang hoặc tỉnh, thành phần khóa địa lý.
`city`	`varchar(100)`	NN; FK5	Thành phố, thành phần khóa địa lý.

Tên trường	Kiểu dữ liệu	Ràng buộc	Mô tả
region	varchar(50)	NN; FK5	Vùng theo nguồn, thành phần khóa địa lý.
market	varchar(20)	NN; FK5	Thị trường, thành phần khóa địa lý.
customer_id	varchar(20)	NN; FK3, FK6	Mã khách hàng; cũng tham gia khóa tham chiếu đơn hàng.
order_id	varchar(30)	NN; FK6	Mã đơn nguồn; không dùng riêng để đếm đơn.
weeknum	smallint	NN; CHECK 1–53	Tuần theo nguồn, giữ riêng với tuần ISO tại Dim_Date.
sales	numeric(18,5)	NN; CHECK ≥ 0	Doanh thu dòng, giữ cả trường hợp bằng 0.
profit	numeric(18,5)	NN	Lợi nhuận dòng; cho phép giá trị âm.
quantity	smallint	NN; CHECK > 0	Số lượng bán trên dòng.
discount	numeric(6,4)	NN; CHECK 0–1	Tỷ lệ chiết khấu; không cộng trực tiếp.
shipping_cost	numeric(18,5)	NN; CHECK ≥ 0	Phí vận chuyển ghi nhận trên dòng.
profit_margin	numeric(18,8)	Cho phép NULL; CHECK theo doanh thu	Biên lợi nhuận dòng; NULL khi doanh thu bằng 0, khớp lợi nhuận chia doanh thu khi doanh thu dương.

Bảng 8: Sáu khóa ngoại của Fact_Sales

Mã	Trường tham chiếu trong Fact	Bảng chiều và khóa được tham chiếu
FK1	order_date	Dim_Date: full_date.
FK2	ship_date	Dim_Date: full_date.
FK3	customer_id	Dim_Customer: customer_id.
FK4	product_id, product_name	Dim_Product: product_id, product_name.
FK5	country, state, city, region, market	Dim_Geography: country, state, city, region, market.

Mã	Trường tham chiếu trong Fact	Bảng chiều và khóa được tham chiếu
FK6	`order_id`, `order_date`, `customer_id`	Dim_Order: `order_id`, `order_date`, `customer_id`.

Mỗi FK ghép là một ràng buộc trên toàn bộ tổ hợp theo đúng thứ tự đã liệt kê. Ngoài các điều kiện từng cột, SQL kiểm tra `ship_date >= order_date`. Với `sales = 0`, `profit_margin` phải NULL. Với `sales > 0`, tỷ lệ phải khác NULL và thỏa mãn

$$\left| m_i - \text{round}\left(\frac{p_i}{s_i}, 8\right) \right| \leq 10^{-8},$$

trong đó m_i, p_i và s_i lần lượt là biên lợi nhuận, lợi nhuận và doanh thu của dòng. Quy tắc này phục vụ kiểm tra tỷ lệ lưu trên Fact; KPI biên lợi nhuận tổng hợp vẫn phải tính từ tổng lợi nhuận chia tổng doanh thu của phạm vi phân tích.

Bảng chiều thời gian `Dim_Date`

`Dim_Date` lưu một bản ghi cho mỗi ngày lịch, phục vụ phân tích theo năm, quý, tháng và tuần. Hai trường `order_date` và `ship_date` tại bảng sự kiện cùng tham chiếu đến `full_date`, lần lượt theo vai trò ngày đặt và ngày gửi.

Bảng 9: Thiết kế bảng `Dim_Date`

Tên trường (Attribute)	Kiểu dữ liệu	Ràng buộc	Mô tả
`full_date`	`date`	PK; NN	Ngày lịch duy nhất, dùng để liên kết với ngày đặt và ngày gửi.
`calendar_year`	`smallint`	NN; CHECK D1	Năm lịch của `full_date`.
`calendar_quarter`	`smallint`	NN; CHECK 1–4; D2	Quý trong năm, được xác định từ ngày lịch.
`calendar_month`	`smallint`	NN; CHECK 1–12; D3	Tháng trong năm, phục vụ phân tích theo tháng.
`iso_year`	`smallint`	NN; CHECK D4	Năm theo lịch tuần ISO; có thể khác năm lịch ở đầu hoặc cuối năm.
`iso_week`	`smallint`	NN; CHECK 1–53; D5	Số tuần ISO, sử dụng cùng `iso_year`; không thay thế `weeknum` nguồn.

Các ký hiệu D1–D5 trong Bảng 9 dùng để tham chiếu năm điều kiện CHECK đối chiếu thuộc tính với ngày lịch trong DDL của bản triển khai chính. Đây là ký hiệu trình bày trong báo cáo, không phải tên ràng buộc trong database. PK đồng thời bảo đảm tính duy nhất và NOT NULL của `full_date`; các thuộc tính còn lại đều khai báo NOT NULL.

Bảng 10: Các CHECK đối chiếu thuộc tính của `Dim_Date`

Mã	Điều kiện CHECK trong SQL
D1	`calendar_year = EXTRACT(YEAR FROM full_date)`
D2	`calendar_quarter = EXTRACT(QUARTER FROM full_date)`
D3	`calendar_month = EXTRACT(MONTH FROM full_date)`
D4	`iso_year = EXTRACT(ISOYEAR FROM full_date)`
D5	`iso_week = EXTRACT(WEEK FROM full_date)`

Các CHECK miền giá trị dùng `BETWEEN 1 AND 4` cho quý, `BETWEEN 1 AND 12` cho tháng và `BETWEEN 1 AND 53` cho tuần ISO. Các điều kiện này kiểm tra từng bản ghi; tính liên tục và phạm vi 1.468 ngày được kiểm tra riêng khi phát sinh và đối soát chiều thời gian.

Bảng chiều khách hàng `Dim_Customer`

`Dim_Customer` lưu thông tin mô tả khách hàng và phân khúc. Khóa chính là `customer_id`; không sử dụng tên làm khóa vì nhiều mã khách hàng có thể trùng tên.

Bảng 11: Thiết kế bảng `Dim_Customer`

Tên trường (Attribute)	Kiểu dữ liệu	Ràng buộc	Mô tả
`customer_id`	`varchar(20)`	PK; NN	Mã khách hàng theo nguồn, dùng liên kết với bảng sự kiện.
`customer_name`	`varchar(100)`	NN	Tên khách hàng; không yêu cầu duy nhất.
`segment`	`varchar(30)`	NN	Phân khúc: Consumer, Corporate hoặc Home Office.

Bảng chiều sản phẩm `Dim_Product`

`Dim_Product` lưu thông tin sản phẩm cùng hai cấp phân loại là ngành hàng và nhóm

sản phẩm. Do một mã sản phẩm có thể gắn với nhiều tên, khóa chính được chọn là cặp `product_id` và `product_name`. Qua khảo sát, cặp này xác định nhất quán ngành hàng và nhóm sản phẩm trong dữ liệu hiện tại.

Bảng 12: Thiết kế bảng `Dim_Product`

Tên trường (Attribute)	**Kiểu dữ liệu**	**Ràng buộc**	**Mô tả**
`product_id`	`varchar(30)`	Thành phần PK ghép; NN	Mã sản phẩm nguồn, không duy nhất khi xét riêng.
`product_name`	`varchar(255)`	Thành phần PK ghép; NN	Tên sản phẩm, kết hợp với mã để phân biệt các sản phẩm cùng mã.
`category`	`varchar(50)`	NN	Ngành hàng: Furniture, Office Supplies hoặc Technology.
`sub_category`	`varchar(50)`	NN	Nhóm sản phẩm chi tiết trong ngành hàng, chẳng hạn Chairs, Paper hoặc Phones.

Bảng chiều địa lý `Dim_Geography`

`Dim_Geography` phục vụ phân tích theo địa điểm, vùng và thị trường kinh doanh. Khóa chính gồm năm trường `country`, `state`, `city`, `region` và `market`. Việc chỉ dùng quốc gia, bang và thành phố chưa đủ vì một số tổ hợp địa điểm trong nguồn gắn với nhiều vùng hoặc thị trường. Thuộc tính `market_group` được giữ để tổng hợp US và Canada thành North America.

Bảng 13: Thiết kế bảng `Dim_Geography`

Tên trường (Attribute)	**Kiểu dữ liệu**	**Ràng buộc**	**Mô tả**
`country`	`varchar(100)`	Thành phần PK ghép; NN	Quốc gia gắn với dòng bán hàng.
`state`	`varchar(100)`	Thành phần PK ghép; NN	Bang hoặc tỉnh theo dữ liệu nguồn.

Tên trường (Attribute)	Kiểu dữ liệu	Ràng buộc	Mô tả
city	varchar(100)	Thành phần PK ghép; NN	Thành phố; không dùng riêng làm định danh địa điểm.
region	varchar(50)	Thành phần PK ghép; NN	Vùng theo cách phân loại của nguồn.
market	varchar(20)	Thành phần PK ghép; NN	Thị trường kinh doanh như US, Canada, EU hoặc APAC.
market_group	varchar(30)	NN	Nhóm thị trường tổng hợp; US và Canada thuộc North America.

Bảng chiều đơn hàng Dim_Order

Dim_Order lưu phương thức vận chuyển và mức ưu tiên của đơn hàng. Khóa chính gồm order_id, order_date và customer_id, vì mã đơn nguồn có thể được sử dụng ở nhiều ngày hoặc cho nhiều khách hàng. Ba trường này được sử dụng đồng thời khi liên kết với Fact_Sales.

Bảng 14: Thiết kế bảng Dim_Order

Tên trường (Attribute)	Kiểu dữ liệu	Ràng buộc	Mô tả
order_id	varchar(30)	Thành phần PK ghép; NN	Mã đơn nguồn, không được dùng riêng để xác định đơn.
order_date	date	Thành phần PK ghép; NN	Ngày đặt hàng, tham gia phân biệt các đơn cùng mã.
customer_id	varchar(20)	Thành phần PK ghép; NN	Mã khách hàng đặt đơn.
ship_mode	varchar(30)	NN	Phương thức vận chuyển: Same Day, First Class, Second Class hoặc Standard Class.
order_priority	varchar(20)	NN	Mức ưu tiên xử lý: Critical, High, Medium hoặc Low.

3 Phương pháp đề xuất

Sau bước khảo sát và làm sạch dữ liệu, nhóm tiến hành đưa dữ liệu vào PostgreSQL theo lược đồ hình sao đã thiết kế. Mục đích là chuyển bảng giao dịch ban đầu thành một kho dữ liệu có thể tổng hợp theo thời gian, sản phẩm, thị trường và khách hàng. Các kết quả phân tích và dự báo sau đó cùng sử dụng nguồn dữ liệu này để tránh tình trạng mỗi chức năng tính toán theo một cách khác nhau.

3.1 Quy trình đưa dữ liệu vào kho

Quy trình được thực hiện theo thứ tự: đọc dữ liệu đã chuẩn hóa, đưa vào bảng trung gian, nạp các bảng chiều, nạp bảng sự kiện và đối chiếu kết quả. Đầu vào của bước này gồm 51.290 dòng và 26 thuộc tính, giữ nguyên mức chi tiết là một dòng hàng trong đơn hàng. Các bước làm sạch đã trình bày ở phần trước không được thực hiện lại theo một quy tắc khác khi nạp kho.

Trước hết, nhóm tạo các bảng trong PostgreSQL, khai báo kiểu dữ liệu, khóa chính và khóa ngoại theo thiết kế. Số lượng được lưu bằng kiểu số nguyên; ngày đặt và ngày gửi được lưu bằng kiểu ngày. Doanh thu, lợi nhuận và phí vận chuyển sử dụng kiểu số thập phân để giữ độ chính xác khi cộng nhiều dòng. Các ràng buộc được bổ sung để ngăn những trường hợp không hợp lệ như số lượng không dương, chiết khấu ngoài khoảng cho phép hoặc ngày gửi trước ngày đặt.

Dữ liệu được đưa vào một bảng trung gian trước khi tách sang các bảng chính. Bảng này giữ cấu trúc gần với dữ liệu đầu vào, giúp việc kiểm tra và phân tách thông tin dễ theo dõi hơn. Đây là nơi tiếp nhận dữ liệu trong mỗi lần nạp, không phải một bảng chiều hay một nguồn dữ liệu phân tích riêng.

3.2 Nạp các bảng chiều và bảng sự kiện

Nhóm nạp năm bảng chiều trước để các dòng bán hàng có thể liên kết đến thông tin mô tả đã tồn tại. Mỗi mã khách hàng được giữ thành một bản ghi. Với sản phẩm, địa lý và đơn hàng, việc lấy các bản ghi phân biệt dựa trên toàn bộ tổ hợp khóa đã xác định ở phần thiết kế. Chẳng hạn, hai dòng có cùng mã sản phẩm nhưng khác tên sẽ không bị gộp thành một sản phẩm. Cách xử lý này giữ được các khác biệt trong nguồn và tránh làm nhân số dòng khi nối bảng.

Riêng chiều thời gian được tạo thành dãy ngày liên tục từ 01/01/2011 đến 07/01/2015, bao phủ cả ngày đặt và ngày gửi hàng. Các thuộc tính năm, quý, tháng và tuần ISO được xác định từ từng ngày lịch. Dù giao dịch chỉ có ngày đặt đến cuối năm 2014, chiều thời gian vẫn cần những ngày đầu năm 2015 vì một số đơn được gửi trong khoảng này. Ngày

đặt và ngày gửi cùng tham chiếu đến chiều thời gian nhưng mang hai ý nghĩa khác nhau.

Sau khi các bảng chiều đã được nạp, dữ liệu bán hàng được chuyển sang bảng sự kiện. Mỗi dòng tiếp tục được nhận diện bằng mã dòng gốc, đồng thời liên kết đến khách hàng, sản phẩm, địa lý, đơn hàng và hai vai trò thời gian. Doanh thu, lợi nhuận, số lượng, chiết khấu và phí vận chuyển được giữ ở mức dòng hàng. Nhờ đó, các phép tổng hợp đều bắt đầu từ cùng một mức chi tiết và thay đổi theo câu hỏi phân tích.

Khi chạy lại quy trình, bản ghi có khóa đã tồn tại được cập nhật thay vì chèn thêm một bản sao. Các bước nạp được đặt trong cùng một giao dịch: nếu xuất hiện lỗi, thay đổi của lần nạp đó được hoàn tác. Điều này hạn chế tình trạng chỉ một phần dữ liệu đã được cập nhật trong khi phần còn lại chưa hoàn thành. Trong phạm vi đề tài, quy trình phục vụ nạp lại bộ dữ liệu hiện có; nhóm chưa xây dựng cơ chế lưu nhiều phiên bản thay đổi của các bảng chiều.

3.3 Kiểm tra và đối chiếu kết quả nạp

Sau khi nạp, nhóm kiểm tra số bản ghi của từng bảng, tính duy nhất của khóa và khả năng liên kết giữa bảng sự kiện với các bảng chiều. Kết quả được trình bày trong Bảng 15. Số bản ghi ở các bảng chiều được xác định từ những giá trị hoặc tổ hợp phân biệt, nên không bằng số mã đơn lẻ xuất hiện trong dữ liệu gốc.

Bảng 15: Số bản ghi sau khi nạp kho dữ liệu

Bảng	**Số bản ghi**
Chiều thời gian	1.468
Chiều khách hàng	4.873
Chiều sản phẩm	10.768
Chiều địa lý	3.819
Chiều đơn hàng	25.754
Sự kiện bán hàng	51.290

Để kiểm tra việc tách bảng có làm sai lệch thông tin hay không, nhóm nối lại dữ liệu sự kiện với các bảng chiều rồi đối chiếu từng dòng và 26 thuộc tính với đầu vào. Kết quả vẫn có đủ 51.290 dòng, không bị mất hay nhân bản qua các phép nối; cả sáu quan hệ khóa ngoại đều hợp lệ. Việc kiểm tra cũng được thực hiện sau khi nạp lại để bảo đảm số dòng không tăng chỉ vì chạy quy trình thêm một lần.

Nhóm đồng thời so sánh các tổng quan trọng trước và sau khi nạp. Tổng doanh thu là 12.642.905, tổng lợi nhuận là 1.467.457,29128, tổng số lượng bán là 178.312 và tổng phí vận chuyển là 1.352.815,70340. Cả bốn chỉ tiêu đều có chênh lệch bằng 0. Những con số này được dùng làm mốc kiểm tra cho các phép tổng hợp ở bước OLAP.

Các trường hợp đặc biệt cũng được giữ nguyên, gồm 12.544 dòng lợi nhuận âm và một dòng doanh thu bằng 0. Biên lợi nhuận của dòng doanh thu bằng 0 được để trống vì không thể chia cho 0. Việc giữ các dòng này giúp kết quả phản ánh cả những giao dịch kém hiệu quả, thay vì chỉ mô tả phần dữ liệu có lợi nhuận dương.

3.4 Kết nối với phần phân tích

Từ các bảng trong kho, nhóm xây dựng một lớp dữ liệu phân tích bằng cách nối bảng sự kiện với các chiều theo đúng khóa đã thiết kế. Lớp dữ liệu này cung cấp các chỉ tiêu bán hàng cùng thông tin thời gian, sản phẩm, thị trường và khách hàng, làm đầu vào thống nhất cho truy vấn OLAP và mô hình dự báo.

Dashboard Streamlit hiển thị kết quả dưới dạng chỉ tiêu tổng quan, biểu đồ và bảng chi tiết. Người dùng có thể chọn khoảng tháng, thị trường và ngành hàng để thu hẹp phạm vi phân tích. Phần dự báo sử dụng doanh thu tháng theo từng ngành hàng trên toàn bộ thị trường, nên có phạm vi riêng với bộ lọc OLAP. Cách tổ chức này giúp người dùng xem lại kết quả kinh doanh đã xảy ra, sau đó tham khảo dự báo cho kỳ tiếp theo.

4 Phân tích OLAP và mô hình dự đoán

4.1 Cách tổ chức phân tích OLAP

Nhóm xây dựng các phép tổng hợp để trả lời ba nhóm câu hỏi chính: kết quả kinh doanh thay đổi thế nào theo thời gian; sản phẩm và thị trường nào đóng góp nhiều doanh thu, lợi nhuận; khách hàng, vận chuyển và chiết khấu có những điểm nào cần theo dõi. Mỗi truy vấn chọn phạm vi giao dịch, nối thông tin mô tả cần thiết, sau đó nhóm dữ liệu theo chiều phân tích tương ứng.

Doanh thu và lợi nhuận của một phạm vi được tính bằng tổng các dòng hàng thuộc phạm vi đó. Biên lợi nhuận được tính từ hai tổng này:

$$\text{Biên lợi nhuận} = \frac{\text{Tổng lợi nhuận}}{\text{Tổng doanh thu}} \times 100\%. \tag{1}$$

Nếu tổng doanh thu bằng 0 thì tỷ lệ không được tính. Số đơn hàng là số tổ hợp phân biệt giữa mã đơn, ngày đặt và mã khách hàng, thay vì số dòng hoặc chỉ số mã đơn. Tăng trưởng doanh thu được tính theo công thức:

$$g_t = \frac{S_t - S_{t-k}}{S_{t-k}} \times 100\%, \tag{2}$$

trong đó S_t là doanh thu tháng t; $k = 1$ khi so với tháng trước và $k = 12$ khi so với cùng tháng năm trước. Tỷ lệ được để trống nếu chưa có kỳ so sánh hoặc doanh thu kỳ so sánh bằng 0.

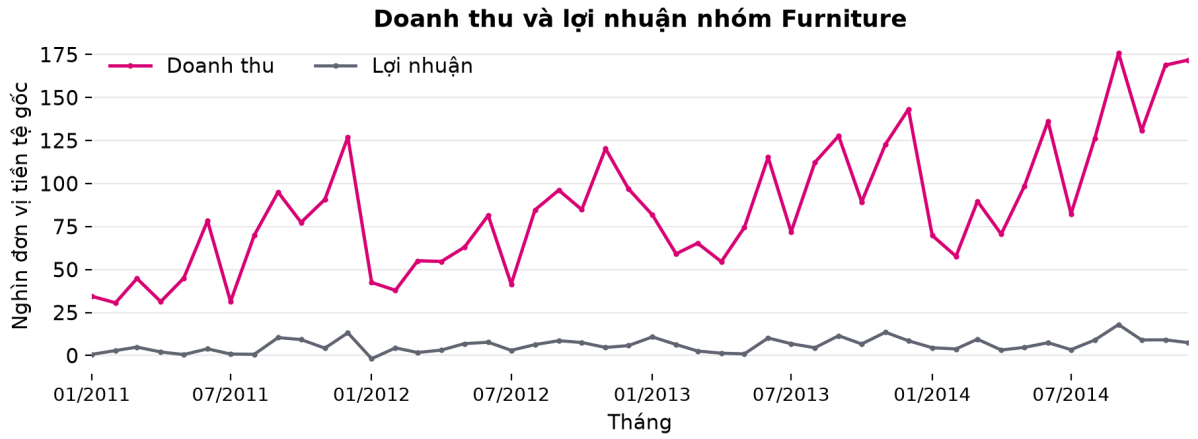
Các thao tác OLAP được áp dụng theo những cấp dữ liệu có trong kho. Với thời gian, nhóm sử dụng *roll-up* để tổng hợp từ tháng lên quý và năm. Với sản phẩm, *drill-down* cho phép đi từ ba ngành hàng xuống 17 phân nhóm sản phẩm. Phép *slice* và *dice* được dùng khi chọn một ngành hàng, khoảng thời gian hoặc một số thị trường; còn *cube* cho phép xem đồng thời kết quả theo thị trường, ngành hàng và các mức tổng của chúng. Khi đọc bảng có dòng tổng hợp, cần phân biệt dòng chi tiết với dòng tổng để không cộng trùng số liệu.

Nhóm đã xây dựng 12 truy vấn, bao quát tổng quan, tăng trưởng theo tháng, phân cấp thời gian, sản phẩm, địa lý, khách hàng, đơn hàng, vận chuyển và chiết khấu. Các biểu đồ dưới đây sử dụng toàn bộ giai đoạn 2011–2014 và toàn bộ thị trường. Các đại lượng tiền tệ được trình bày theo đơn vị gốc của bộ dữ liệu, không tự quy đổi sang một loại tiền tệ khác.

4.2 Tổng quan

4.2.1 Nhóm hàng Furniture

Trong cả giai đoạn, Furniture đạt doanh thu 4.110.884 và lợi nhuận 285.204,72. Doanh thu năm tăng từ 756.171 vào năm 2011 lên 1.378.061 vào năm 2014. Hình 2 cho thấy doanh thu tăng về quy mô qua các năm nhưng vẫn có sự lên xuống giữa các tháng. Tháng 09/2014 đạt doanh thu cao nhất của nhóm, với 175.775.

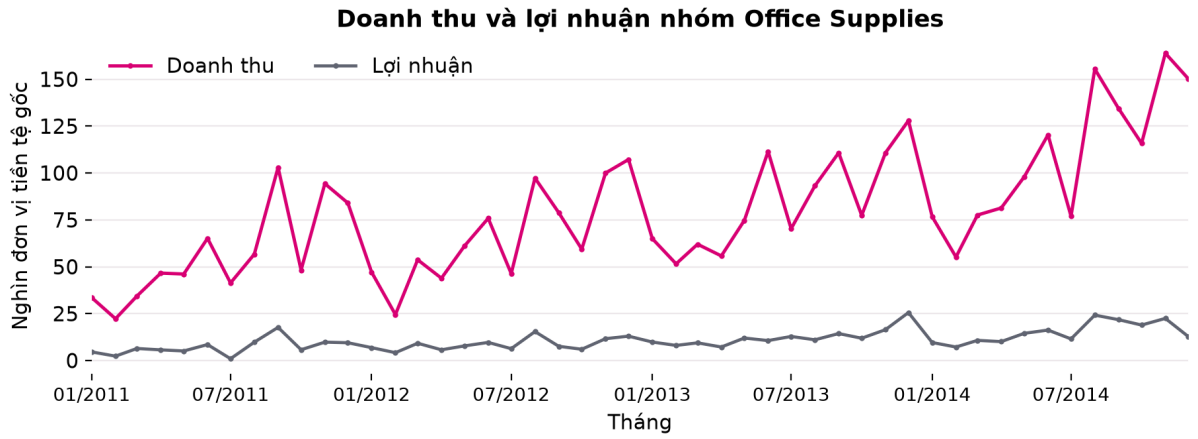


Hình 2: Doanh thu và lợi nhuận theo tháng của nhóm Furniture

So với doanh thu, lợi nhuận của Furniture có khoảng cách khá lớn trên biểu đồ. Biên lợi nhuận toàn kỳ chỉ đạt 6,94%, thấp nhất trong ba ngành hàng. Riêng năm 2014, doanh thu tăng 23,29% so với năm 2013 nhưng biên lợi nhuận giảm từ 7,52% xuống 6,48%. Vì vậy, nhóm này cần được xem xét thêm ở mức phân nhóm sản phẩm để biết doanh thu tăng có đi kèm hiệu quả tương ứng hay không.

4.2.2 Nhóm hàng Office Supplies

Office Supplies đạt doanh thu 3.787.330 và lợi nhuận 518.473,83 trong toàn kỳ. Doanh thu năm 2014 là 1.305.782, tăng 29,18% so với năm 2013. Trên Hình 3, các tháng ở giai đoạn sau nhìn chung có doanh thu cao hơn giai đoạn đầu; tháng 11/2014 đạt mức cao nhất là 163.871.

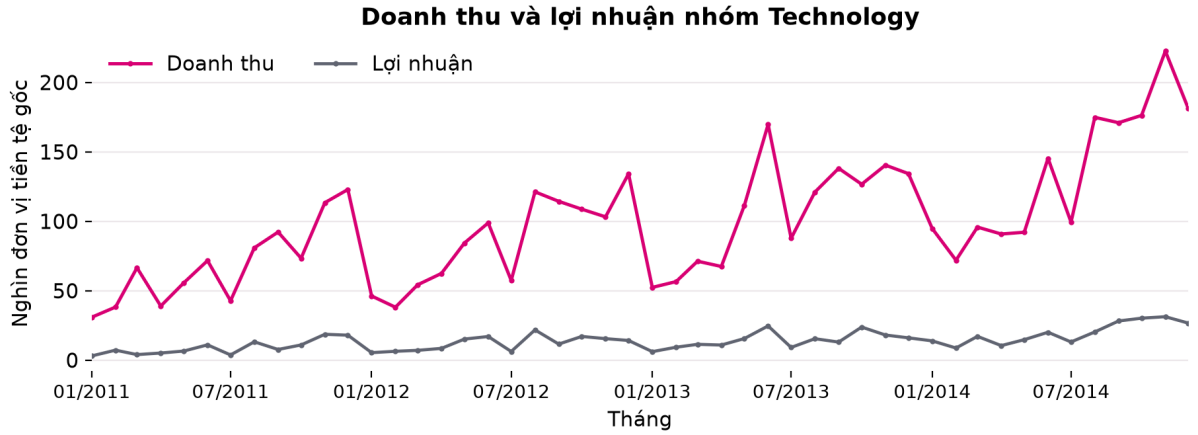


Hình 3: Doanh thu và lợi nhuận theo tháng của nhóm Office Supplies

Dù có tổng doanh thu thấp nhất trong ba ngành hàng, Office Supplies mang lại lợi nhuận cao hơn Furniture. Biên lợi nhuận toàn kỳ đạt 13,69%, gần gấp đôi Furniture. Nếu chỉ xếp hạng theo doanh thu thì vai trò của Office Supplies trong kết quả kinh doanh sẽ chưa được thể hiện đầy đủ.

4.2.3 Nhóm hàng Technology

Technology đứng đầu cả doanh thu và lợi nhuận, lần lượt đạt 4.744.691 và 663.778,73. Nhóm này đóng góp 37,53% doanh thu nhưng chiếm đến 45,23% lợi nhuận toàn bộ dữ liệu. Doanh thu năm 2014 đạt 1.616.198, tăng 26,53% so với năm trước.

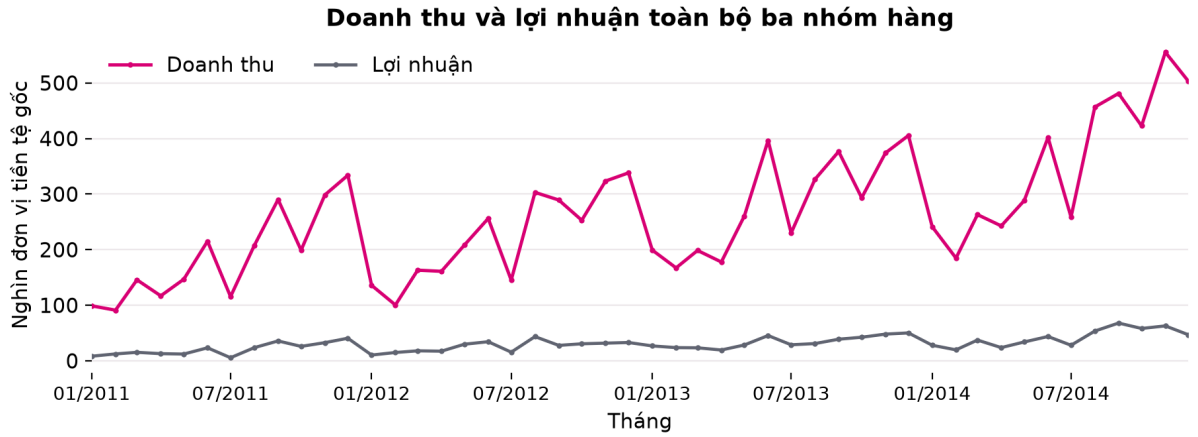


Hình 4: Doanh thu và lợi nhuận theo tháng của nhóm Technology

Hình 4 cho thấy doanh thu cao nhất vào tháng 11/2014, đạt 222.587. Sang tháng 12, doanh thu giảm 18,64% so với tháng trước nhưng vẫn tăng 34,82% so với tháng 12/2013. Vì vậy, việc giảm trong một tháng chưa đủ để kết luận nhóm hàng đang suy giảm dài hạn. Cần xem đồng thời tăng trưởng so với tháng trước và so với cùng kỳ để có nhận xét phù hợp hơn.

4.2.4 Kết quả chung của ba nhóm hàng

Khi cộng ba ngành hàng, tổng doanh thu toàn kỳ đạt 12.642.905 và tổng lợi nhuận đạt 1.467.457,29, tương ứng biên lợi nhuận 11,61%. Doanh thu theo năm lần lượt là 2.259.511, 2.677.493, 3.405.860 và 4.300.041. Mức tăng trưởng năm 2012, 2013 và 2014 lần lượt đạt 18,50%, 27,20% và 26,25%.



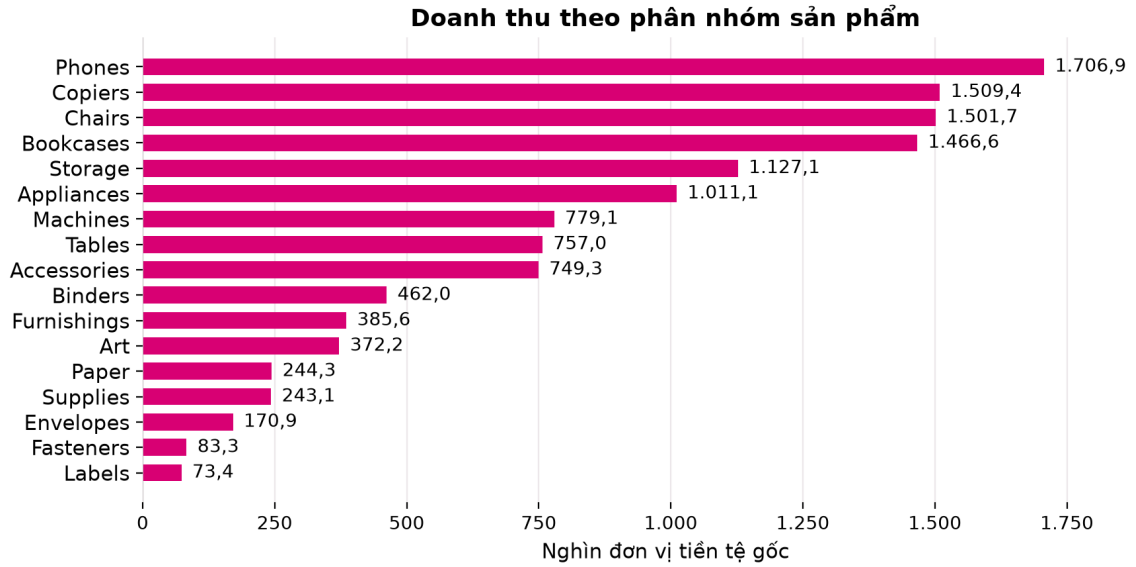
Hình 5: Doanh thu và lợi nhuận theo tháng của toàn bộ ba nhóm hàng

Xu hướng tăng được thể hiện rõ trên Hình 5, nhưng đóng góp của từng nhóm có sự khác nhau. Technology là nguồn lợi nhuận lớn nhất, Office Supplies có hiệu quả tương đối tốt, còn Furniture có doanh thu đáng kể nhưng biên lợi nhuận thấp. Kết quả tổng quan vì thế là điểm bắt đầu để phân tích sâu hơn, chưa thể thay thế việc xem xét từng sản phẩm và thị trường.

4.3 Sản phẩm và thị trường

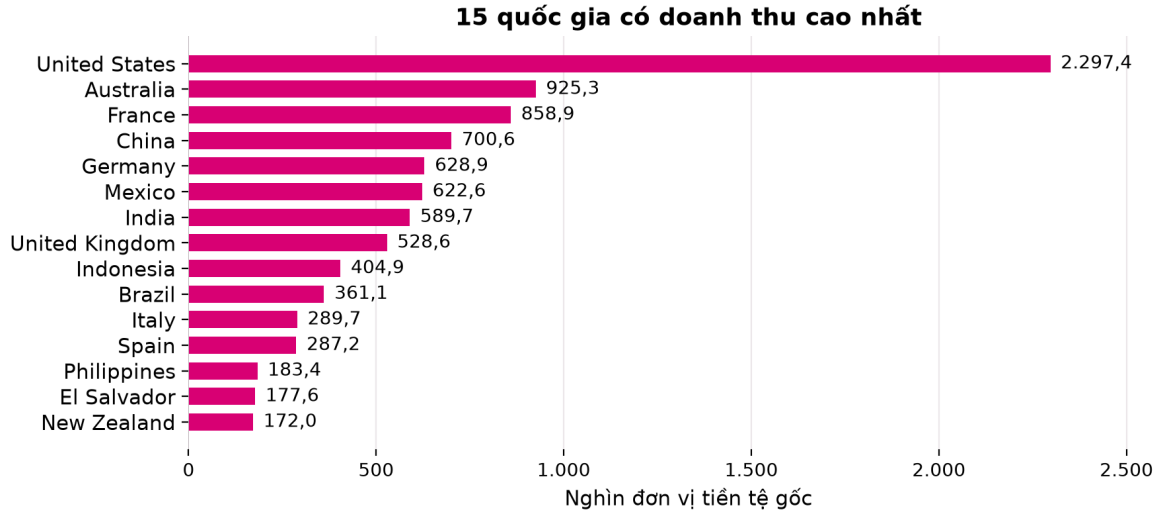
4.3.1 Phân tích doanh thu

Ở mức phân nhóm sản phẩm, Phones đứng đầu doanh thu với 1.706.874, tiếp theo là Copiers với 1.509.439 và Chairs với 1.501.682. Bookcases cũng có đóng góp lớn, đạt 1.466.559. Hình 6 cho thấy doanh thu tập trung nhiều ở một số phân nhóm, trong khi các nhóm như Labels có quy mô nhỏ hơn rõ rệt.



Hình 6: Doanh thu theo phân nhóm sản phẩm trong giai đoạn 2011–2014

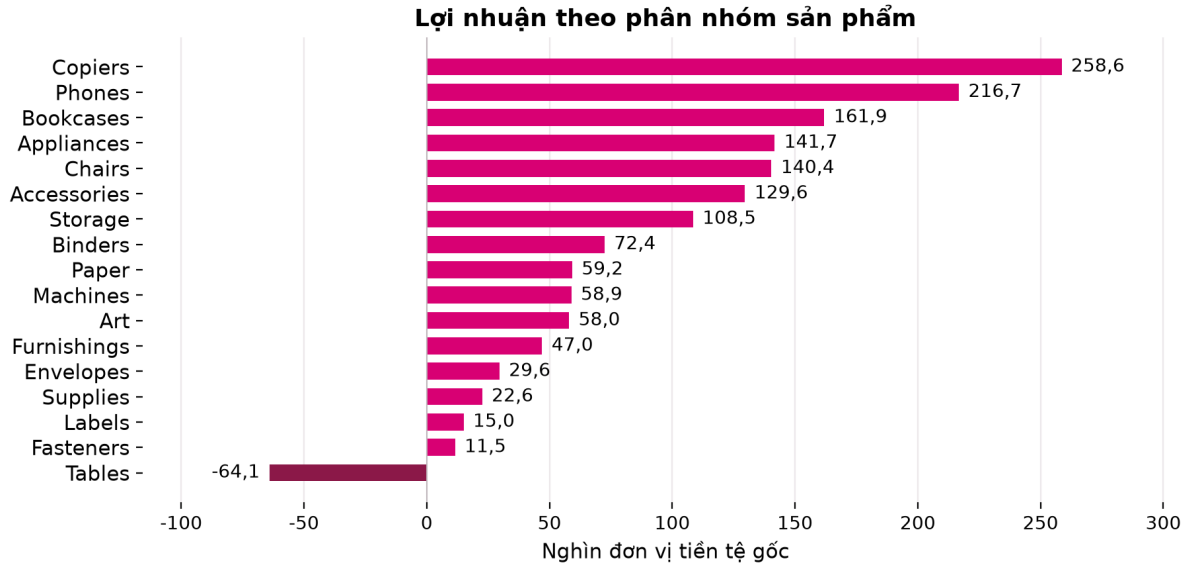
Theo quốc gia, United States dẫn đầu với doanh thu 2.297.354. Các vị trí tiếp theo là Australia với 925.257, France với 858.930, China với 700.591 và Germany với 628.857. Biểu đồ Top 15 ở Hình 7 giúp xác định những quốc gia đóng góp nhiều vào quy mô bán hàng, làm cơ sở chọn phạm vi cần phân tích chi tiết trên dashboard.



Hình 7: Mười lăm quốc gia có doanh thu cao nhất

4.3.2 Phân tích lợi nhuận

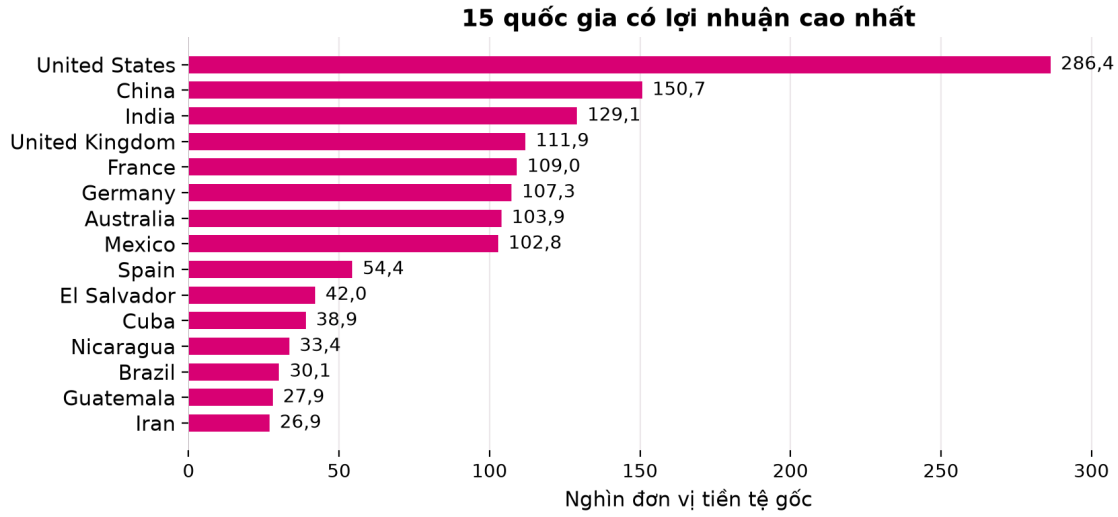
Thứ hạng theo lợi nhuận không hoàn toàn giống thứ hạng theo doanh thu. Copiers mang lại lợi nhuận lớn nhất, đạt 258.567,55, cao hơn Phones với 216.717,01. Chairs có doanh thu gần bằng Copiers nhưng chỉ tạo ra lợi nhuận 140.396,27. Hai phân nhóm có doanh thu tương đương vẫn có thể khác nhau đáng kể về lợi nhuận đóng góp.



Hình 8: Lợi nhuận theo phân nhóm sản phẩm trong giai đoạn 2011–2014

Điểm đáng chú ý nhất trên Hình 8 là Tables có tổng lợi nhuận âm 64.083,39 dù doanh thu đạt 757.034, tương ứng biên lợi nhuận $-8,47\%$. Đây là phân nhóm duy nhất bị lỗ khi tổng hợp toàn kỳ, đồng thời làm giảm hiệu quả chung của Furniture. Kết quả này gợi ý cần rà soát các dòng hàng Tables theo sản phẩm, thị trường và mức chiết khấu, thay vì chỉ tìm cách tăng doanh thu của cả ngành hàng.

Theo quốc gia, United States tiếp tục đứng đầu về lợi nhuận với 286.397,02. Tuy nhiên, các vị trí sau thay đổi so với biểu đồ doanh thu: China đạt 150.683,09, India đạt 129.071,84 và United Kingdom đạt 111.900,15. Australia đứng thứ hai về doanh thu nhưng chỉ đứng thứ bảy về lợi nhuận.



Hình 9: Mười lăm quốc gia có lợi nhuận cao nhất

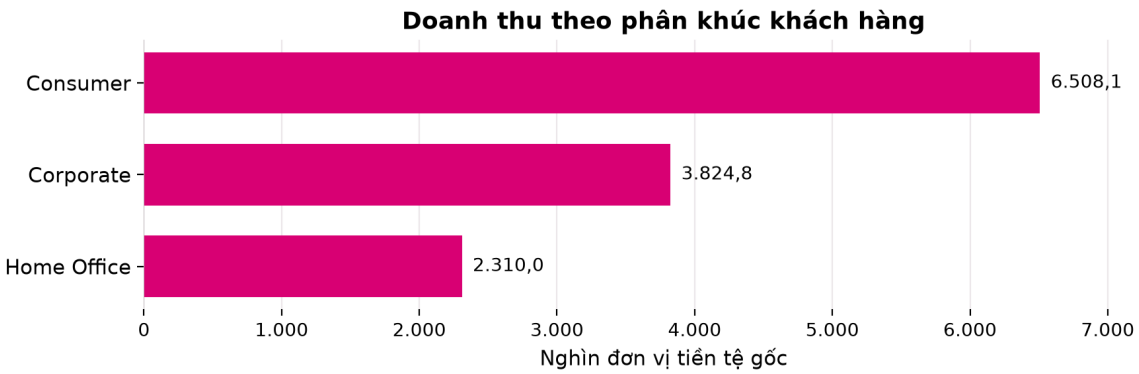
Biên lợi nhuận của China và India lần lượt đạt 21,51% và 21,89%, trong khi Australia

đạt 11,23%. Ngoài ra, Philippines xuất hiện trong Top 15 doanh thu nhưng có tổng lợi nhuận âm 16.128,23. Những khác biệt này cho thấy cần đọc kết hợp hai biểu đồ: doanh thu phản ánh quy mô, còn lợi nhuận và biên lợi nhuận giúp đánh giá hiệu quả trong phạm vi dữ liệu.

4.4 Khách hàng và đơn hàng

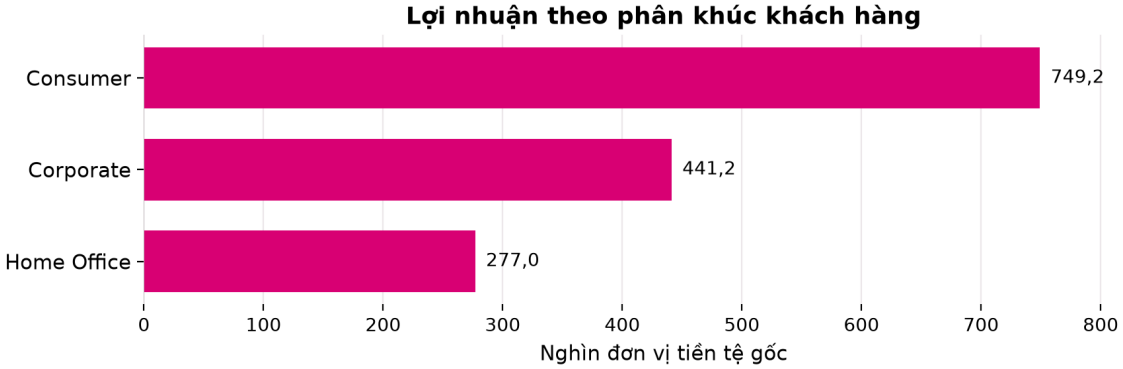
4.4.1 Doanh thu và lợi nhuận theo phân khúc

Consumer là phân khúc đóng góp lớn nhất với doanh thu 6.508.141, chiếm 51,48% tổng doanh thu. Corporate đạt 3.824.808 và Home Office đạt 2.309.956. Hình 10 cho thấy chênh lệch rõ về quy mô giữa ba phân khúc, trong đó Consumer là nguồn doanh thu chính của bộ dữ liệu.



Hình 10: Doanh thu theo phân khúc khách hàng

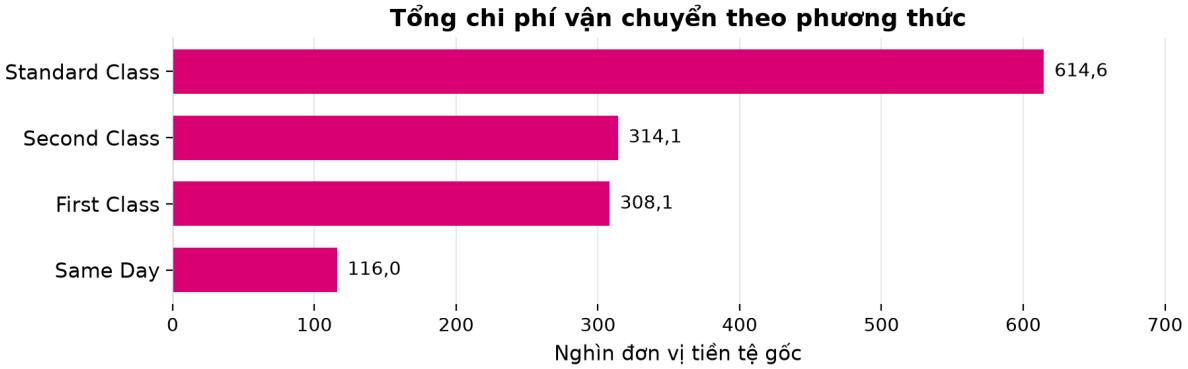
Lợi nhuận của Consumer đạt 749.239,78, tiếp theo là Corporate với 441.208,33 và Home Office với 277.009,18. Thứ hạng lợi nhuận trong Hình 11 giống thứ hạng doanh thu. Tuy vậy, biên lợi nhuận của ba nhóm khá gần nhau: Consumer đạt 11,51%, Corporate đạt 11,54% và Home Office đạt 11,99%. Khác biệt về đóng góp chủ yếu nằm ở quy mô giao dịch; chưa thể xem Consumer là phân khúc có hiệu quả tương đối vượt trội chỉ vì lợi nhuận tuyệt đối cao nhất.



Hình 11: Lợi nhuận theo phân khúc khách hàng

4.4.2 Vận chuyển và chiết khấu

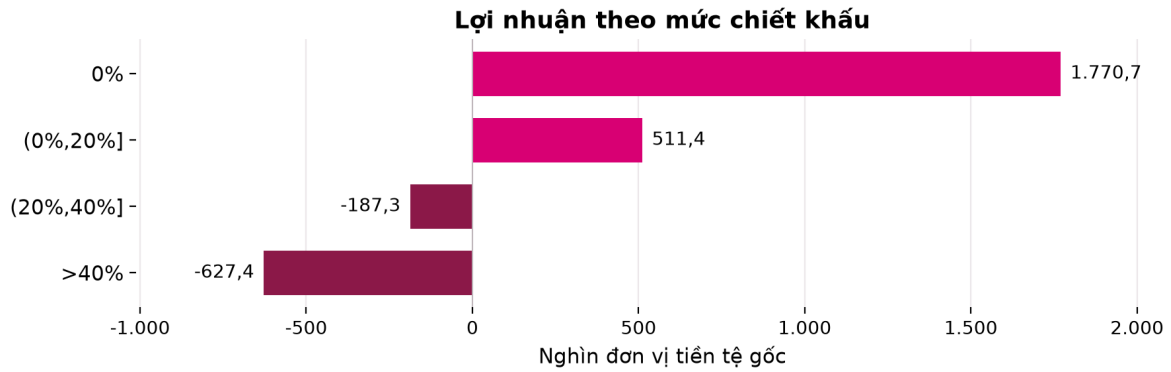
Standard Class có tổng phí vận chuyển lớn nhất, đạt 614.627,66. Second Class và First Class lần lượt đạt 314.111,79 và 308.102,54; Same Day có tổng phí thấp nhất là 115.973,72. Tuy nhiên, Standard Class cũng có số đơn lớn nhất, với 15.412 đơn, trong khi Same Day chỉ có 1.349 đơn.



Hình 12: Tổng phí vận chuyển theo phương thức giao hàng

Vì biểu đồ thể hiện tổng phí, không nên kết luận Standard Class kém hiệu quả nhất chỉ dựa vào độ dài cột. Khi chia tổng phí cho số đơn tương ứng, phí bình quân của Standard Class khoảng 39,88 mỗi đơn, thấp hơn Same Day với khoảng 85,97 mỗi đơn. So sánh này cho thấy cần xét thêm quy mô đơn hàng khi đọc kết quả vận chuyển. Để đánh giá sâu hơn, vẫn cần xem khác biệt về địa lý, sản phẩm và mức ưu tiên của các đơn.

Với chiết khấu, nhóm chia dữ liệu thành bốn mức: không chiết khấu, trên 0% đến 20%, trên 20% đến 40% và trên 40%. Tổng lợi nhuận tương ứng lần lượt là 1.770.695,27; 511.444,10; $-187.271,06$ và $-627.411,02$. Hình 13 thể hiện sự chênh lệch rõ giữa hai mức chiết khấu thấp và hai mức cao.



Hình 13: Tổng lợi nhuận theo các mức chiết khấu

Các giao dịch có chiết khấu trên 40% tạo ra doanh thu 846.335 nhưng lỗ 627.411,02; tỷ lệ dòng lỗ trong mức này là 98,43%. Đây là nhóm giao dịch cần được ưu tiên rà soát theo sản phẩm và thị trường. Tuy nhiên, kết quả hiện tại chỉ là mối liên hệ trong dữ liệu lịch sử. Nhóm chưa kiểm soát các yếu tố khác để khẳng định chiết khấu cao là nguyên nhân duy nhất gây lỗ, hoặc giảm chiết khấu sẽ chắc chắn làm lợi nhuận tăng.

4.5 Mô hình dự báo doanh thu

4.5.1 Mục tiêu và chuẩn bị dữ liệu

Phần OLAP giúp nhìn lại hoạt động kinh doanh đã diễn ra, còn mô hình dự báo được bổ sung để hỗ trợ lập kế hoạch cho tháng tiếp theo. Nhóm lựa chọn dự báo doanh thu riêng cho Furniture, Office Supplies và Technology. Mức tổng hợp theo ngành hàng giúp chuỗi có đủ giao dịch ở mỗi tháng và phù hợp với phạm vi dữ liệu chỉ kéo dài bốn năm.

Đầu vào được tạo bằng cách cộng doanh thu theo tháng đặt hàng và ngành hàng từ kho dữ liệu. Mỗi ngành hàng có 48 tháng liên tục từ 01/2011 đến 12/2014, tổng cộng 144 quan sát. Trước khi huấn luyện, nhóm kiểm tra thứ tự thời gian, tháng bị thiếu và đối chiếu các tổng doanh thu với nguồn. Các tháng đều có giá trị, nên không cần tự bổ sung doanh thu cho tháng thiếu.

4.5.2 Phương pháp Holt–Winters và mô hình đối chứng

Nhóm thử phương pháp Holt–Winters với xu hướng cộng và mùa vụ cộng, chu kỳ 12 tháng. Phương pháp này kết hợp ba thành phần: mức doanh thu gần nhất, xu hướng tăng giảm và khác biệt giữa các tháng trong năm [8]. Cách biểu diễn này phù hợp để thử nghiệm với chuỗi doanh thu có mức tăng qua các năm và biến động theo tháng.

Gọi y_t là doanh thu thực tế tháng t, ℓ_t là mức doanh thu, b_t là xu hướng và s_t là

thành phần mùa vụ. Các thành phần được cập nhật như sau:

$$\ell_t = \alpha(y_t - s_{t-12}) + (1-\alpha)(\ell_{t-1} + b_{t-1}), \tag{3}$$

$$b_t = \beta(\ell_t - \ell_{t-1}) + (1-\beta)b_{t-1}, \tag{4}$$

$$s_t = \gamma(y_t - \ell_{t-1} - b_{t-1}) + (1-\gamma)s_{t-12}. \tag{5}$$

Trong đó, α, β và γ là các hệ số làm trơn trong khoảng từ 0 đến 1. Các hệ số và giá trị ban đầu được ước lượng từ dữ liệu huấn luyện. Dự báo một tháng tiếp theo được tính bằng:

$$\widehat{y}_{t+1|t} = \ell_t + b_t + s_{t-11}. \tag{6}$$

Nói cách khác, doanh thu dự báo được ghép từ mức hiện tại, phần tăng giảm dự kiến trong một tháng và ảnh hưởng mùa vụ của tháng sắp tới. Nhóm sử dụng cách cập nhật các thành phần theo triển khai Holt–Winters của thư viện statsmodels [9].

Để đánh giá mô hình có mang lại cải thiện hay không, nhóm dùng cách lấy doanh thu cùng tháng năm trước làm đối chứng. Khi dự báo tháng $t+1$, phương pháp này cho kết quả $\widehat{y}_{t+1|t} = y_{t-11}$. Nhóm cũng thử một biến thể Holt–Winters có giảm dần xu hướng, nhằm tránh kéo dài mức tăng quá mạnh. Như vậy, có ba phương án được so sánh trên cùng dữ liệu và cùng cách đánh giá.

4.5.3 Cách chia dữ liệu và đánh giá

Dữ liệu không được chia ngẫu nhiên vì các tháng có thứ tự thời gian. Nhóm dùng giai đoạn 2011–2012 làm lịch sử ban đầu, năm 2013 để chọn mô hình và năm 2014 để kiểm tra sau khi đã chọn. Với chu kỳ mùa vụ 12 tháng, hai năm đầu cung cấp hai chu kỳ cho lần huấn luyện đầu tiên.

Trong cả năm chọn mô hình và năm kiểm tra, dự báo được thực hiện cuốn chiếu trước một tháng. Tại mỗi mốc, mô hình chỉ sử dụng các tháng đã xảy ra, dự báo tháng tiếp theo rồi so với số thực tế của tháng đó. Sau khi đã biết thực tế, tháng vừa kiểm tra mới được bổ sung vào lịch sử cho lần dự báo kế tiếp. Ví dụ, dự báo tháng 02/2014 được phép dùng thực tế tháng 01/2014, nhưng không được dùng dữ liệu từ tháng 02 trở đi. Vì vậy, kết quả thể hiện khả năng dự báo từng tháng khi có cập nhật dữ liệu, không phải dự báo đồng thời cả năm 2014 từ cuối năm 2013.

Nhóm sử dụng ba chỉ số MAE, RMSE và WAPE. Với $e_i = y_i - \widehat{y}_i$ là sai số tại tháng

kiểm tra thứ i và n là số tháng được đánh giá:

$$\text{MAE} = \frac{1}{n}\sum_{i=1}^{n}|e_i|, \tag{7}$$

$$\text{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}e_i^2}, \tag{8}$$

$$\text{WAPE} = \frac{\sum_{i=1}^{n}|e_i|}{\sum_{i=1}^{n}|y_i|} \times 100\%. \tag{9}$$

MAE cho biết độ lệch tuyệt đối trung bình theo đơn vị doanh thu; RMSE nhạy hơn với các tháng có sai số lớn. WAPE biểu diễn tổng độ lệch so với tổng doanh thu thực tế và được dùng để chọn mô hình. Cả ba chỉ số càng nhỏ càng tốt. WAPE không phải tỷ lệ phân loại đúng, nên không lấy 100% − WAPE để gọi là độ chính xác của mô hình.

Bảng 16: WAPE trên năm 2013 dùng để lựa chọn mô hình

Ngành hàng	Cùng tháng năm trước	Holt–Winters	Holt–Winters giảm xu hướng
Furniture	23,18%	**12,09%**	12,71%
Office Supplies	22,16%	**8,93%**	9,01%
Technology	19,91%	**13,39%**	13,57%

Theo Bảng 16, Holt–Winters không giảm xu hướng có WAPE thấp nhất ở cả ba ngành hàng, nên được giữ lại cho bước kiểm tra năm 2014. Đây là mô hình tốt nhất trong ba phương án nhóm đã thử theo tập lựa chọn, không có nghĩa là tốt nhất trong mọi phương pháp dự báo. Kết quả năm 2014 không được dùng để chọn lại mô hình.

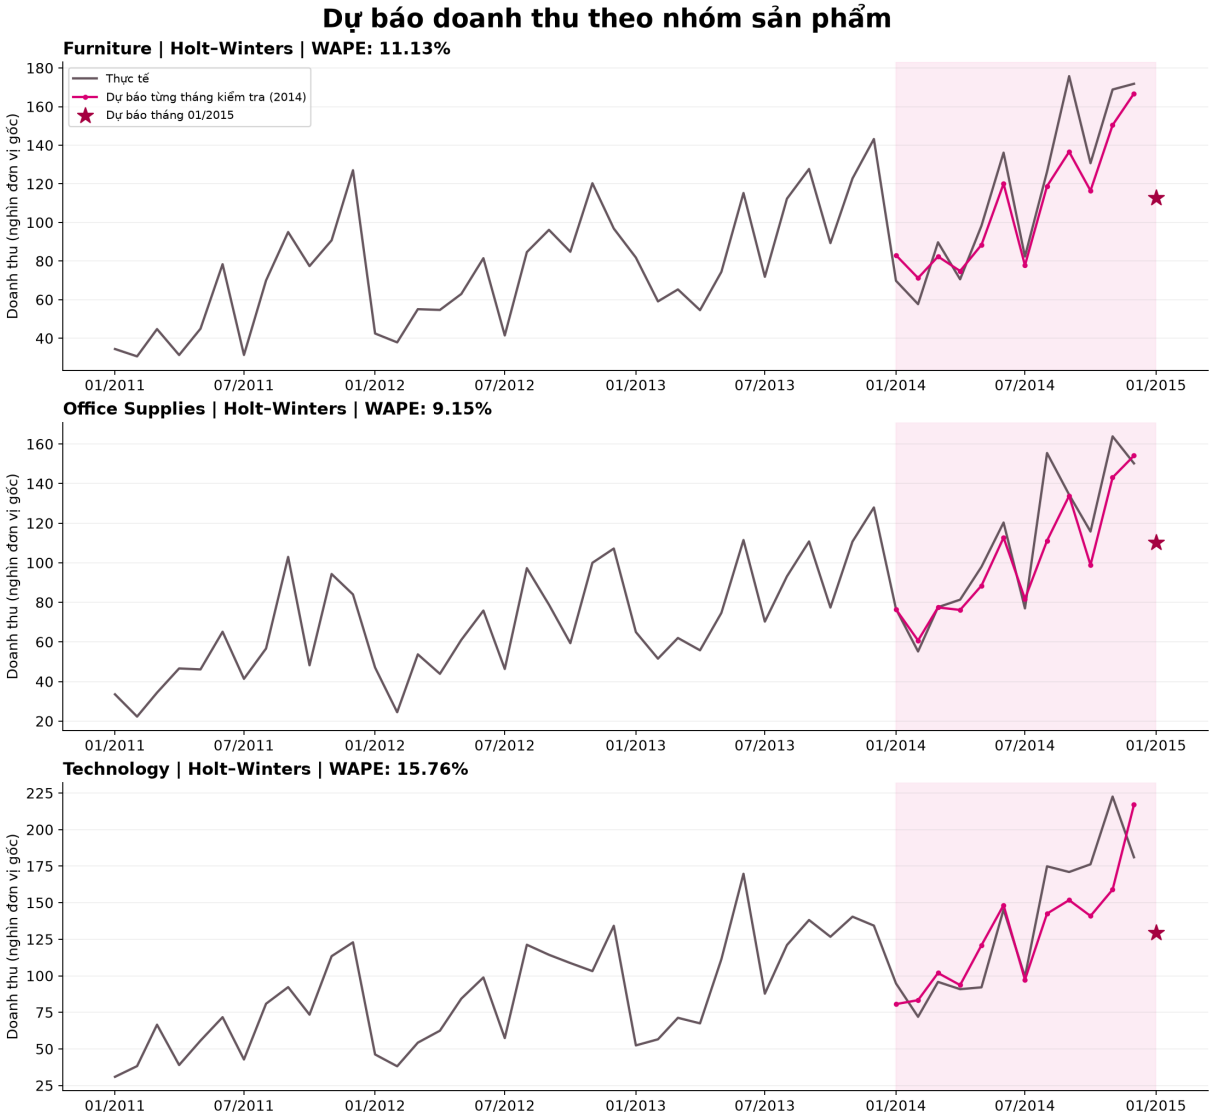
4.5.4 Kết quả kiểm tra và dự báo tháng tiếp theo

Kết quả trên 12 tháng của năm 2014 được trình bày trong Bảng 17. Holt–Winters có WAPE thấp hơn phương pháp đối chứng ở cả ba ngành hàng. Office Supplies có sai số tương đối thấp nhất, còn Technology có sai số cao nhất trong lần kiểm tra này.

Bảng 17: Kết quả dự báo cuốn chiếu trên năm 2014

Ngành hàng	WAPE đối chứng	WAPE Holt–Winters	MAE	RMSE
Furniture	20,84%	11,13%	12.777,32	15.723,76
Office Supplies	22,59%	9,15%	9.953,57	15.610,73
Technology	26,37%	15,76%	21.231,49	27.721,75

Khi gộp sai số trên 36 cặp ngành hàng–tháng, WAPE giảm từ 23,45% ở đối chứng xuống 12,27% ở mô hình được chọn. Nếu cộng doanh thu dự báo của ba ngành hàng thành tổng mỗi tháng rồi so với tổng thực tế, WAPE đạt 9,63%, trong khi đối chứng là 20,79%. Hai kết quả khác nhau vì sai số giữa các ngành hàng có thể bù trừ khi cộng thành tổng; WAPE tổng không được tính bằng trung bình ba WAPE riêng.



Hình 14: Doanh thu thực tế, dự báo kiểm tra năm 2014 và dự báo tháng 01/2015 theo ngành hàng

Trên Hình 14, đường dự báo bám được phần biến động chung nhưng vẫn có những tháng lệch khá rõ so với thực tế, nhất là Technology ở cuối năm 2014. Đây là điểm cần lưu ý khi dùng kết quả để lập mục tiêu. Mô hình cho một mức doanh thu tham khảo, không bảo đảm doanh thu thực tế sẽ đạt đúng giá trị đó.

Sau đánh giá, nhóm huấn luyện lại mô hình đã chọn bằng toàn bộ 48 tháng để dự báo tháng 01/2015. Kết quả theo từng ngành hàng được trình bày trong Bảng 18. Tổng doanh thu dự báo được cộng từ các giá trị chưa làm tròn của ba ngành hàng.

Bảng 18: Dự báo doanh thu tháng 01/2015 theo đơn vị gốc

Ngành hàng	**Doanh thu dự báo**
Furniture	112.812,22
Office Supplies	110.231,22
Technology	129.332,40
Tổng	**352.375,83**

Tháng 01/2015 nằm ngay sau thời điểm kết thúc dữ liệu đặt hàng và chưa có số thực tế trong bộ dữ liệu để tính sai số. Kết quả này minh họa chức năng dự báo theo mốc lịch sử của bài tập, không phải dự báo cho tháng hiện tại. Trên dashboard, người dùng có thể xem dự báo từng ngành hàng, tổng doanh thu và các chỉ số đánh giá để cân nhắc khi lập kế hoạch.

Trong phạm vi đề tài, dự báo hỗ trợ đặt mục tiêu doanh thu và lựa chọn nhóm hàng cần theo dõi. Chưa thể chuyển trực tiếp doanh thu dự báo thành số lượng cần nhập vì dữ liệu chưa có thông tin tồn kho và giá vốn đầy đủ. Ngoài ra, bộ dữ liệu chỉ có bốn năm lịch sử, kết quả mới được kiểm tra trên một năm và chưa có khoảng dự báo. Những hạn chế này cần được giữ rõ khi sử dụng mô hình để hỗ trợ quyết định.

5 Demo Dashboard

Dashboard phục vụ hai nhu cầu: phân tích kết quả bán hàng lịch sử bằng OLAP và tham khảo dự báo doanh thu để lập kế hoạch tháng tiếp theo. Người dùng có thể lọc khoảng tháng, thị trường và ngành hàng khi xem các chỉ tiêu lịch sử. Phần DSS hiển thị dự báo tháng 01/2015 theo ba ngành hàng và tổng doanh thu, cùng MAE, RMSE, WAPE để đánh giá mức sai số. Dự báo được tính trên toàn bộ thị trường với dữ liệu đến tháng 12/2014; các bộ lọc OLAP không làm thay đổi phạm vi huấn luyện mô hình.

Luồng demo bắt đầu bằng việc xem tổng quan, đi sâu vào ngành hàng hoặc thị trường cần theo dõi, sau đó mở trang dự báo để đối chiếu doanh thu tháng tiếp theo và sai số kiểm tra. Kết quả cung cấp mức doanh thu tham khảo khi đặt mục tiêu bán hàng, với phương pháp và giới hạn đã trình bày tại Mục 4.5.

Đường dẫn ứng dụng: https://superstore-data-warehouse-h8pdzdsvdkvtphhcc8wmzu.streamlit.app/.

Tài liệu tham khảo

[1] `fatihilhan`, *Global Superstore Dataset*, Kaggle. https://www.kaggle.com/datasets/fatihilhan/global-superstore-dataset.

[2] Học phần Kho dữ liệu và hệ hỗ trợ quyết định (CO4031), *Yêu cầu bài tập lớn, học kỳ 261*. Tài liệu học phần do giảng viên cung cấp.

[3] Nhóm phát triển pandas, *pandas User Guide*. Các mục về đọc và ghi CSV, xử lý văn bản, giá trị thiếu, ngày tháng và tổng hợp dữ liệu. https://pandas.pydata.org/docs/user_guide/index.html.

[4] The PostgreSQL Global Development Group, *PostgreSQL Documentation*. Tài liệu về kiểu dữ liệu, khóa và ràng buộc, giao dịch, nạp dữ liệu và cập nhật bản ghi. https://www.postgresql.org/docs/current/.

[5] The PostgreSQL Global Development Group, *Table Expressions*, chương 7 của PostgreSQL Documentation. Các mục về tổng hợp dữ liệu, grouping sets, cube, rollup và hàm cửa sổ. https://www.postgresql.org/docs/current/queries-table-expressions.html.

[6] The PostgreSQL Global Development Group và EDB, *Windows Installers; PostgreSQL Binaries*. Nguồn cài đặt PostgreSQL cho môi trường chạy cục bộ. https://www.postgresql.org/download/windows/; https://www.enterprisedb.com/download-postgresql-binaries.

[7] Nhóm phát triển Psycopg, *Passing Parameters to SQL Queries*, tài liệu Psycopg 3. https://www.psycopg.org/psycopg3/docs/basic/params.html.

[8] Rob J. Hyndman và George Athanasopoulos, *Forecasting: Principles and Practice*, ấn bản thứ ba, OTexts. Chương 5: The Forecaster's Toolbox; chương 8: Exponential Smoothing. https://otexts.com/fpp3/toolbox.html; https://otexts.com/fpp3/exponential-smoothing.html.

[9] Nhóm phát triển statsmodels, *ExponentialSmoothing: Holt–Winters Exponential Smoothing*, tài liệu thư viện statsmodels. https://www.statsmodels.org/stable/generated/statsmodels.tsa.holtwinters.ExponentialSmoothing.html.

[10] Nhóm phát triển Matplotlib, *Pyplot Tutorial*, tài liệu hướng dẫn vẽ và trình bày biểu đồ bằng Matplotlib. https://matplotlib.org/stable/tutorials/pyplot.html.

[11] draw.io, *Generate and Validate draw.io Diagrams with AI*, tài liệu tham chiếu về cấu trúc XML và kiểm tra sơ đồ draw.io. https://www.drawio.com/docs/reference/diagram-generation/.

[12] Streamlit, *st.altair_chart*, tài liệu hiển thị biểu đồ Altair trên ứng dụng Streamlit. https://docs.streamlit.io/develop/api-reference/charts/st.altair_chart.

[13] Streamlit, *st.testing.v1.AppTest*, tài liệu kiểm thử ứng dụng và các thành phần giao diện Streamlit. https://docs.streamlit.io/develop/api-reference/app-testing/st.testing.v1.apptest.

[14] Streamlit, *Manage Your App*, tài liệu triển khai, cập nhật và quản lý ứng dụng trên Streamlit Community Cloud. https://docs.streamlit.io/deploy/streamlit-community-cloud/manage-your-app.